

Interfaces cerebro-cloud para la predicción de actividades de imaginación motriz

Ing. Freddy Julian Riascos Salas

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Jaime Andrés Riascos Salas (Potsdam Embodied Cognition Group)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Pasto, junio de 2026

Resumen

En la presente memoria se describe el desarrollo de un sistema de inteligencia artificial enfocado en la predicción de tareas de imaginación motriz usando señales de electroencefalografía. Este trabajo busca dejar una base técnica para el desarrollo de sistemas de interacción cerebro-computador en imaginación motriz para predecir la intención de movimiento en usuarios.

Para su implementación fueron necesarios los conocimientos adquiridos en la especialización incluidos procesamiento y análisis de datos, aprendizaje automático, redes neuronales y operaciones.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Interfaces cerebro-computador	1
1.1.1. Arquitectura funcional de un sistema BCI	1
1.1.2. Dispositivos de adquisición de señales EEG	2
1.2. Estado del arte	2
1.3. Motivación	3
1.4. Objetivos y alcance	4
1.4.1. Objetivo general	4
1.4.2. Objetivos específicos	4
1.4.3. Alcance	4
2. Introducción específica	5
2.1. Adquisición de datos	5
2.1.1. Configuración técnica y estructura del conjunto de datos	5
2.2. Métodos tradicionales en EEG y extracción automática de caracte- rísticas	7
2.3. Arquitecturas de redes neuronales para EEG en tareas de imagina- ción motriz	8
3. Diseño e implementación	11
3.1. Arquitectura del sistema	11
4. Ensayos y resultados	13
4.1. Pruebas funcionales del hardware	13
5. Conclusiones	15
5.1. Conclusiones generales	15
5.2. Próximos pasos	15
Bibliografía	17

Índice de figuras

2.1. Distribución de electrodos según el sistema 10-20 utilizado en la adquisición de señales EEG.	6
2.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.	8
3.1. Diagrama de la arquitectura general del sistema.	12

Índice de tablas

1.1. Comparativa de enfoques	3
2.1. dataset dreier	6
2.2. Comparación entre modelos	7
2.3. Comparación entre arquitecturas	9

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presentan los fundamentos de las tecnologías de interfaz cerebro-computador y se describe el estado actual de la investigación en el área. Asimismo, se exponen la motivación, los objetivos y el alcance definidos para el desarrollo del trabajo.

1.1. Interfaces cerebro-computador

Las interfaces cerebro-computador o BCI (del inglés, *Brain-Computer Interface*) se definen como sistemas que establecen una vía de comunicación directa entre el cerebro humano y un dispositivo externo [1]. Estos sistemas permiten la traducción de patrones de actividad cerebral en comandos de control sin la intervención de las vías periféricas neuromusculares tradicionales.

El funcionamiento de una BCI se fundamentó en la adquisición de señales bioeléctricas, su procesamiento digital y la posterior ejecución de acciones en un entorno computacional o físico. En el desarrollo de este trabajo, se consideraron las señales electroencefalográficas o EEG (del inglés, *electroencephalogram*) debido a su naturaleza no invasiva y su capacidad para registrar la intención motriz del usuario en tiempo real. La integración de estos dispositivos con servicios en la nube facilita el procesamiento de grandes volúmenes de datos, lo que permite optimizar la capacidad de respuesta de los sistemas ante tareas de imaginación motriz.

1.1.1. Arquitectura funcional de un sistema BCI

El modelo operativo de una BCI inicia con una cadena de procesamiento compuesta por etapas secuenciales. En la fase inicial, se realiza la adquisición de señales mediante sensores electroencefalográficos colocados sobre el cuero cabelludo. Luego, los datos crudos se someten a procesos de preprocesamiento para la eliminación de artefactos, tales como parpadeos o movimientos musculares, mediante el uso de filtros digitales. Posteriormente, se realiza la extracción de características que permite identificar los componentes relevantes de la señal asociados a la intención del usuario. Finalmente, se implementan algoritmos de clasificación para traducir dichas características en comandos de control.

En este contexto, la imaginación motriz se define como el proceso cognitivo en el que un individuo simula mentalmente una acción motora sin ejecutar un movimiento físico real [2]. Este fenómeno produce cambios detectables en los ritmos

sensorimotrices de la corteza cerebral, específicamente en las bandas de frecuencia mu (8–13 Hz) y beta (13–30 Hz), que constituyen la base fisiológica para la decodificación de la intención de movimiento en sistemas BCI.

1.1.2. Dispositivos de adquisición de señales EEG

La captura de la actividad eléctrica cerebral se realiza habitualmente mediante sistemas de EEG. Estos se clasifican según su movilidad y el tipo de sensores empleados. En el ámbito de la investigación, se destacan dispositivos de grado médico y equipos portátiles diseñados para aplicaciones fuera del entorno clínico, estos han sido ampliamente abordados en la literatura científica[3]. Aunque en este trabajo se utilizó un conjunto de datos o dataset previamente registrado, la comprensión de estos dispositivos resultó pertinente para el análisis de la calidad de la señal.

1.2. Estado del arte

La presente revisión del estado del arte tiene como objetivo identificar las metodologías dominantes en la clasificación de tareas de imaginación motriz mediante EEG. En los últimos años, el estudio de las BCI ha cobrado relevancia debido a la convergencia entre la neurociencia computacional y el aprendizaje profundo, lo que permite aprender directamente de las señales crudas, sin depender de métodos tradicionales de extracción de características como el patrón espacial común o CSP (del inglés, *Common Spatial Pattern*) [4].

Las redes neuronales convolucionales o CNN (del inglés, *Convolutional Neural Network*) constituyen una de las aproximaciones más utilizadas. Estas redes capturan patrones espaciales en las señales EEG y han demostrado un buen desempeño en la clasificación de tareas de imaginación motriz. Modelos como EEGNet introducen arquitecturas compactas que logran buenos resultados incluso con pocos datos de entrenamiento [5].

Por otra parte, las redes recurrentes, especialmente las de memoria a corto y largo plazo o LSTM (del inglés, *Long Short-Term Memory*), permiten modelar la dinámica temporal de las señales EEG. Estas arquitecturas capturan dependencias en el tiempo que resultan clave para identificar patrones asociados a la imaginación de movimiento. Estudios recientes reportan que modelos basados en LSTM alcanzan desempeños superiores frente a métodos tradicionales [6].

Asimismo, las arquitecturas híbridas que combinan CNN y LSTM han ganado relevancia. Estas combinaciones permiten integrar información espacial y temporal en un mismo modelo. Investigaciones muestran que este enfoque mejora la capacidad de generalización y aumenta la precisión en comparación con modelos individuales [6, 7].

En los trabajos más recientes, se han propuesto variantes más eficientes como redes convolucionales ligeras y modelos que operan en el dominio frecuencial. Estas propuestas buscan reducir la complejidad del modelo y mejorar el rendimiento con conjuntos de datos limitados, lo que representa un desafío común en aplicaciones de interfaces cerebro-computador [8].

La literatura técnica muestra un interés en el desplazamiento desde los métodos basados en la extracción manual de características, como los CSP, hacia sistemas

de aprendizaje profundo. Mientras que los algoritmos tradicionales destacan por su baja carga computacional, las investigaciones recientes exponen que las arquitecturas híbridas logran una mayor robustez ante la variabilidad entre sujetos. Sin embargo, aún persisten retos relacionados con la variabilidad entre usuarios, la necesidad de grandes volúmenes de datos y la robustez en entornos reales [6].

En la tabla 1.1 se presenta la comparativa técnica de las arquitecturas y enfoques identificados en la revisión bibliográfica.

TABLA 1.1. Comparativa de enfoques tecnológicos para la clasificación de imaginación motriz.

Enfoque	Técnicas	Ventajas	Limitaciones
Estadístico	CSP + SVM	Alta interpretabilidad y eficiencia en sistemas embebidos.	Sensible a artefactos y requiere calibración manual.
Redes Convolucionales	CNN (EEGNet)	Reducción de parámetros y extracción automática de rasgos.	Necesidad de grandes volúmenes de datos etiquetados.
Arquitectura Híbrida	CNN + LSTM	Modelado de dependencias temporales y espaciales.	Complejidad computacional elevada y riesgo de sobreajuste.

1.3. Motivación

El desarrollo de este trabajo se justificó en la necesidad de mejorar la precisión en la predicción de la intención de movimiento de un usuario a partir de señales EEG asociadas a tareas de imaginación motriz. A pesar de los avances en el procesamiento de señales biológicas, los métodos tradicionales presentan dificultades para adaptarse a la variabilidad de los ritmos sensorimotrices entre diferentes individuos, lo que limita su aplicación en entornos reales fuera del laboratorio y representa un desafío significativo para la generalización en sistemas EEG [1, 9].

La implementación de modelos de inteligencia artificial avanzados permitió abordar la naturaleza no lineal y compleja de las señales de imaginación motriz, que presentan una alta variabilidad entre sujetos. Durante el análisis preliminar, se identificó que el procesamiento local en dispositivos embebidos restringía el uso de arquitecturas de aprendizaje profundo debido a las limitaciones de memoria y capacidad de cómputo de los sistemas portátiles. Por lo tanto, la integración de una infraestructura en la nube se presentó como una solución técnica viable para ejecutar modelos de alta complejidad sin comprometer la portabilidad ni la autonomía del sistema de adquisición.

Asimismo, la motivación de este trabajo residió en la creación de una arquitectura escalable que facilitara el entrenamiento continuo de los modelos. Al centralizar el procesamiento, se permitió la acumulación de datos para el refinamiento de los algoritmos, que busca una reducción significativa en el tiempo de calibración requerido para cada usuario. Esta aproximación tecnológica no solo optimizó el rendimiento predictivo, sino que también sentó las bases para interfaces cerebro-computador más robustas y eficientes en la práctica clínica y asistencial.

1.4. Objetivos y alcance

El desarrollo de este trabajo se orientó a la creación de una infraestructura tecnológica capaz de procesar y clasificar señales EEG en un entorno distribuido. A continuación, se presentan el objetivo general, los objetivos específicos y el alcance del trabajo.

1.4.1. Objetivo general

Establecer una base técnica que permitiera analizar patrones neuronales asociados a tareas de imaginación motriz, que integra modelos de inteligencia artificial y servicios en la nube para servir como referencia en futuros desarrollos de interfaces cerebro-computador.

1.4.2. Objetivos específicos

Para cumplir con el objetivo general, se plantearon los siguientes objetivos específicos:

- Implementar una arquitectura de red neuronal capaz de identificar con precisión las intenciones de movimiento a partir de señales EEG.
- Diseñar un flujo de datos que integrara la adquisición de señales con el procesamiento remoto en una plataforma en la nube.
- Evaluar el desempeño del sistema mediante métricas de precisión y tiempo de respuesta en la clasificación de actividades de imaginación motriz.
- Documentar los procedimientos de preprocesamiento y entrenamiento para facilitar la replicabilidad del modelo en investigaciones posteriores.

1.4.3. Alcance

El alcance de este trabajo comprendió desde la selección y limpieza del conjunto de datos hasta el despliegue del modelo de inferencia en servidores remotos. Se limitó el estudio al análisis de tareas motoras binarias como el movimiento imaginado de la mano izquierda y la derecha. Se utilizan datasets de acceso público para garantizar la validación estadística de los resultados.

El sistema se diseñó para operar de forma asíncrona, que prioriza la precisión del clasificador sobre la respuesta inmediata de baja latencia. Se establece así un marco de trabajo robusto para la investigación de algoritmos complejos. No se incluyó en esta etapa el desarrollo de hardware de adquisición propio ni la implementación de biorretroalimentación en tiempo real para el usuario final.

Capítulo 2

Introducción específica

En este capítulo se presentan los procedimientos técnicos para la obtención de señales EEG y los métodos de extracción de características aplicados en este trabajo. Asimismo, se describen las arquitecturas de redes neuronales orientadas a la clasificación de tareas de imaginación motriz.

2.1. Adquisición de datos

El conjunto de datos seleccionado para este trabajo provino de los registros originales publicados por los autores del estudio Dreyer2023A [10], que presenta una base de datos de señales EEG orientada al análisis de la intención motora en sujetos sanos.

Es importante destacar que la adquisición de las señales EEG y el diseño del protocolo experimental fueron realizados por los autores del estudio original. En este trabajo no se llevó a cabo la recolección de datos, sino que se utilizó este conjunto de datos público como base para el desarrollo de los procesos de análisis, modelado y clasificación.

En el estudio original, la recolección de la actividad cerebral se realiza mediante un sistema de alta resolución que permite capturar las variaciones de potencial eléctrico en la corteza cerebral durante la ejecución de tareas mentales específicas, enfocadas en la discriminación de movimientos imaginados.

El protocolo experimental se fundamenta en un paradigma en el que los participantes realizan tareas de intención de movimiento de la mano izquierda y la mano derecha sin ejecución física. Cada ensayo sigue una secuencia temporal estricta que inicia con una fase de advertencia, seguida de una señal visual que indica la dirección del movimiento imaginado. Los sujetos mantienen la actividad mental durante un intervalo de cuatro segundos, lo que permite el registro de los ritmos sensorimotrices asociados a la planificación motora. Las condiciones del experimento se mantienen controladas en una habitación con aislamiento acústico para garantizar la repetibilidad de las mediciones.

2.1.1. Configuración técnica y estructura del conjunto de datos

En el estudio original, la captura de las señales la realizan mediante una distribución de 64 electrodos activos dispuestos según el sistema internacional 10-20, como puede observarse en la figura 2.1; estos se ubican sobre las áreas motoras y somatosensoriales. Esta disposición facilita la detección de los fenómenos de desincronización relacionada con eventos, que resultan fundamentales para la

2.2. Métodos tradicionales en EEG y extracción automática de características

Tradicionalmente, la decodificación de la imaginación motriz se basa en algoritmos de aprendizaje automático combinados con una etapa de ingeniería de rasgos manual. El enfoque más común utiliza CSP, técnica que descompone las señales para maximizar la varianza entre clases y facilitar la separación de estados mentales [11]. A partir de estos patrones, se emplean clasificadores como LDA (del inglés, *Linear Discriminant Analysis*) y SVM (del inglés, *Support Vector Machines*). Aunque efectivos en entornos controlados, estos métodos son sensibles a la colocación de electrodos y requieren ajuste experto de las bandas de frecuencia por sujeto.

Frente a estas limitaciones, el avance hacia el aprendizaje profundo o Deep Learning ha permitido el desarrollo de modelos capaces de realizar la extracción automática de características. A diferencia de los esquemas clásicos, estas arquitecturas aprenden representaciones jerárquicas directamente a partir de los datos crudos, y se reduce la necesidad de una ingeniería de rasgos manual.

Sin embargo, diversos estudios han señalado que la calidad de la adquisición de las señales EEG continúa siendo un factor determinante en el desempeño de estos modelos. Una configuración deficiente en la toma de muestras o una inadecuada colocación de los sensores puede introducir artefactos que las redes neuronales interpretan erróneamente como patrones fisiológicos, lo que afecta la robustez de la predicción. Por lo tanto, aunque los modelos de aprendizaje profundo contengan la capacidad de identificar características complejas, su desempeño depende en gran medida de la calidad y fidelidad de las señales de entrada.

En la tabla 2.2 se presenta una comparación entre los métodos tradicionales de procesamiento de EEG y las técnicas de aprendizaje profundo. Estas destacan sus características, ventajas y limitaciones en el contexto del análisis de señales EEG para la clasificación de tareas de imaginación motriz.

TABLA 2.2. Comparación entre métodos tradicionales y modelos de aprendizaje profundo para el análisis de EEG.

Característica	Métodos Tradicionales (CSP, SVM, LDA)	Aprendizaje Profundo (CNN, EEGNet)
Extracción de rasgos	Manual y basada en conocimiento experto.	Automática a partir de los datos de entrada.
Sensibilidad al ruido	Muy alta, requiere filtros manuales estrictos.	Moderada, depende de la calidad del dato.
Manejo de datos	Requiere segmentación y filtrado previo.	Procesamiento con preprocesamiento mínimo.
Rendimiento	Limitado ante señales no estacionarias.	Mayor robustez y escalabilidad.
Dependencia	Alta dependencia de calibración por sujeto.	Posibilidad de aprendizaje transferido.

2.3. Arquitecturas de redes neuronales para EEG en tareas de imaginación motriz

Las CNN se consolidan como una de las herramientas más eficaces para la extracción de características. Mediante el uso de filtros de convolución, estas redes permiten identificar patrones de activación en regiones específicas de la corteza motora, que simula de manera automática el comportamiento de los filtros espaciales tradicionales. Por ello, el uso de las CNN facilita la detección de cambios en la amplitud de los ritmos sensorimotrices asociados a la intención de movimiento de las extremidades.

Por otro lado, para el análisis de la dinámica temporal de las señales EEG, las redes neuronales recurrentes o RNN (del inglés, *Recurrent Neural Networks*), específicamente las unidades de memoria de largo corto plazo o LSTM (del inglés, *Long Short-Term Memory*) y las unidades recurrentes calificadas o GRU (del inglés, *Gated Recurrent Units*) permiten modelar la evolución de la señal a lo largo del tiempo; estas utilizan mecanismos de puertas para retener información relevante y descartar el ruido transitorio. Mientras que las LSTM emplean una estructura compleja para gestionar la memoria a largo plazo, las GRU ofrecen una alternativa más eficiente en términos computacionales, que mantiene un rendimiento competitivo en la clasificación de series temporales de EEG.

Por último, los enfoques híbridos han sido ampliamente utilizados para integrar las ventajas de distintos modelos en el análisis de señales EEG. En particular, las arquitecturas de tipo CNN-LSTM combinan la capacidad de las redes convolucionales para extraer características espaciales con la habilidad de las redes recurrentes para modelar dependencias temporales [12].

El enfoque híbrido y las arquitecturas de redes neuronales para el análisis de señales EEG se muestran en la figura 2.2, en la que se ilustra la estructura de cada modelo y su aplicación en la clasificación de tareas de imaginación motriz.




FIGURA 2.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.

En este tipo de arquitecturas, las capas convolucionales permiten identificar patrones relevantes en la distribución espacial de los electrodos, mientras que las capas recurrentes procesan la evolución temporal de dichas características. Esta combinación resulta adecuada para el manejo de la alta dimensionalidad de las señales EEG, que facilita la construcción de representaciones robustas previas a la etapa de clasificación.

En la tabla 2.3 se presenta una comparación técnica entre las arquitecturas de redes neuronales aplicadas al análisis de señales EEG, y se destacan las características, ventajas y limitaciones en el contexto de la clasificación de tareas de imaginación motriz. Esta comparación proporciona una visión integral de cómo cada enfoque contribuye al procesamiento de las señales EEG y a la mejora del rendimiento en la decodificación de la intención motora.

TABLA 2.3. Comparación entre arquitecturas CNN, LSTM y CNN-LSTM aplicadas al análisis de señales EEG.

Característica	CNN	LSTM / GRU	CNN-LSTM
Tipo de procesamiento	Espacial (filtros convolucionales)	Temporal (modelado secuencial)	Espacial + temporal combinado
Extracción de características	Automática en dominios espaciales locales	Basada en dependencias temporales	Extracción jerárquica espacio-temporal
Manejo de dependencias temporales	Limitado	Alto (memoria de corto y largo plazo)	Alto (integrado con características espaciales)
Complejidad computacional	Moderada	Alta	Alta
Robustez frente a ruido	Moderada	Moderada	Alta (por integración de representaciones)
Ventaja principal	Detección de patrones espaciales en electrodos	Modelado de dinámica temporal de la señal	Captura conjunta de patrones espaciales y temporales
Limitación principal	No modela secuencias largas	Alto costo y entrenamiento más complejo	Mayor complejidad y necesidad de ajuste fino
Aplicación en EEG	Identificación de activación cortical localizada	Análisis de evolución temporal de ritmos cerebrales	Clasificación integral de tareas de imaginación motriz

Capítulo 3

Diseño e implementación

En este capítulo se describen las etapas de diseño y el ajuste del sistema orientado a la clasificación de tareas de imaginación motriz. En las siguientes secciones se detallan la arquitectura del sistema, el tratamiento de los datos de origen, el desarrollo y entrenamiento de los modelos de aprendizaje profundo, así como el protocolo de evaluación y el despliegue final en la infraestructura de la nube.

3.1. Arquitectura del sistema

En esta sección se describe la arquitectura general del sistema que se utilizó para la predicción de tareas de imaginación motriz a partir de EEG.

El sistema se estructuró como un flujo secuencial compuesto por etapas de preparación de datos, preprocesamiento, extracción de características, inferencia mediante modelos de aprendizaje profundo y despliegue en infraestructura cloud. Este enfoque permitió integrar el procesamiento de señales EEG con servicios distribuidos, facilitando la escalabilidad y la eficiencia en la ejecución de los modelos.

La fuente de datos correspondió al conjunto de datos Dreyer2023A [10]. Este contiene registros de señales EEG asociados a tareas de imaginación motriz. Dicho conjunto fue utilizado como base para el entrenamiento y evaluación de los modelos, sin realizar procesos de adquisición directa de señales.

Luego, se implementó una etapa de preprocesamiento orientada a mejorar la relación entre la señal y el ruido. En esta fase se aplicaron técnicas de filtrado y segmentación, con el fin de aislar ventanas relevantes para el análisis. Este procedimiento permitió reducir la variabilidad inherente a las señales EEG y facilitar el aprendizaje de patrones discriminativos.

La extracción de características se abordó mediante arquitecturas de redes neuronales, que permitieron modelar dependencias espaciales y temporales presentes en las señales. Se consideraron enfoques híbridos capaces de capturar correlaciones entre canales y dinámicas temporales, lo que resulta fundamental en tareas de imaginación motriz [12].

El módulo de inferencia se diseñó para recibir las representaciones procesadas y generar una predicción de la tarea imaginada. Este módulo se integró con un servicio web, que permitió exponer la funcionalidad del modelo por medio de una API RESTful. De esta manera, se facilitaría la interacción con aplicaciones externas y la posibilidad de realizar predicciones en tiempo real.

A continuación, se presenta la arquitectura general del sistema propuesto en la figura 3.1, en la que se ilustran las etapas principales del flujo de procesamiento y su integración dentro del entorno cloud.




FIGURA 3.1. Diagrama de la arquitectura general del sistema.

Finalmente, el sistema se desplegó bajo un paradigma cloud, que permitió desacoplar el procesamiento intensivo del entorno local. Esta arquitectura facilitó la implementación de una interfaz cerebro-computador cloud, en la que las señales fueron procesadas de manera remota para la generación de resultados.

La arquitectura descrita estableció un flujo completo desde la preparación de los datos hasta la obtención de predicciones, garantizando modularidad, escalabilidad y capacidad de integración con aplicaciones externas.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Jonathan R. Wolpaw et al. «Brain-computer interfaces for communication and control». En: *Clinical Neurophysiology* 113.6 (2002), págs. 767-791.
- [2] Gert Pfurtscheller y Christa Neuper. «Motor imagery and direct brain-computer communication». En: *Proceedings of the IEEE* 89.7 (2001), págs. 1123-1134.
- [3] Alexander J. Casson et al. «Wearable electroencephalography». En: *IEEE Engineering in Medicine and Biology Magazine* 29.3 (2010), págs. 44-56.
- [4] Robin Tibor Schirrmeister et al. «Deep learning with convolutional neural networks for EEG decoding and visualization». En: *Human Brain Mapping* 38.11 (2017), págs. 5391-5420.
- [5] Vernon J. Lawhern et al. «EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 15.5 (2018).
- [6] Yannick Roy et al. «Deep learning-based electroencephalography analysis: a systematic review». En: *Journal of Neural Engineering* 16.5 (2019).
- [7] Pouya Bashivan et al. «Learning representations from EEG with deep recurrent-convolutional neural networks». En: *arXiv preprint arXiv:1511.06448* (2015).
- [8] Alexander Craik, Yongtian He y Jose L. Contreras-Vidal. «Deep learning for electroencephalogram (EEG) classification tasks: a review». En: *Journal of Neural Engineering* 16.3 (2019).
- [9] Fabien Lotte et al. «A review of classification algorithms for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 4.2 (2007).
- [10] Alaric M. Dreyer et al. «A large electroencephalography dataset for the study of motor imagery». En: *Scientific Data* 10.1 (2023), págs. 583. DOI: [10.1038/s41597-023-02445-z](https://doi.org/10.1038/s41597-023-02445-z).
- [11] Jaime Riascos, Marta Molinas y Fabien Lotte. «Machine Learning Methods for BCI: challenges, pitfalls and promises». En: *ESANN 2024-European symposium on artificial neural networks, computational intelligence and machine learning*. 2024.
- [12] Ding Zhang et al. «EEG-based brain-computer interfaces using deep learning: A review». En: *Biomedical Signal Processing and Control* 63 (2021), págs. 102172.