

Interfaces Cerebro-Cloud para la predicción de actividades de imaginación motriz

Ing. Freddy Julian Riascos Salas

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Jaime Andrés Riascos Salas (Potsdam Embodied Cognition Group)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Pasto, marzo de 2026

Resumen

En la presente memoria se describe el desarrollo de un sistema de inteligencia artificial enfocado en la predicción de tareas de imaginación motriz usando señales de electroencefalografía. Este trabajo busca dejar una base técnica para el desarrollo de sistemas de interacción cerebro-computador en imaginación motriz para predecir la intención de movimiento en usuarios.

Para su implementación fueron necesarios los conocimientos adquiridos en la especialización incluidos procesamiento y análisis de datos, aprendizaje automático, redes neuronales y operaciones.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Interfaces cerebro-computador	1
1.1.1. Arquitectura funcional de un sistema BCI	1
Imaginación motriz y ritmos sensorimotrices	1
1.1.2. Dispositivos de adquisición de señales EEG	2
1.2. Estado del arte	2
1.3. Motivación	3
1.4. Objetivos y alcance	4
1.4.1. Objetivo general	4
1.4.2. Objetivos específicos	4
1.4.3. Alcance	4
2. Introducción Específica	5
2.1. Adquisición de datos	5
2.1.1. Configuración técnica y estructura del conjunto de datos	5
2.2. Métodos tradicionales para EEG y extracción automática de características	7
2.3. Arquitecturas de redes neuronales para EEG en imaginación motriz	7
3. Diseño e implementación	11
3.1. Análisis del software	11
4. Ensayos y resultados	13
4.1. Pruebas funcionales del hardware	13
5. Conclusiones	15
5.1. Conclusiones generales	15
5.2. Próximos pasos	15
Bibliografía	17

Índice de figuras

2.1. Imagen tomada de la página oficial del procesador ¹	6
2.2. Imagen generada por inteligencia artificial	9

Índice de tablas

1.1. Comparativa de enfoques	3
2.1. dataset dreier	6
2.2. Comparación entre modelos	8
2.3. Comparación entre arquitecturas	9

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presentan los fundamentos de las tecnologías de interfaz cerebro-computador y se describe el estado actual de la investigación en el área. Asimismo, se exponen la motivación, los objetivos y el alcance definidos para el desarrollo del trabajo.

1.1. Interfaces cerebro-computador

Las interfaces cerebro-computador o BCI (del inglés, *Brain-Computer Interface*) se definen como sistemas que establecen una vía de comunicación directa entre el cerebro humano y un dispositivo externo [1]. Estos sistemas permitieron la traducción de patrones de actividad cerebral en comandos de control sin la intervención de las vías periféricas neuromusculares tradicionales.

El funcionamiento de una BCI se fundamentó en la adquisición de señales bioeléctricas, su procesamiento digital y la posterior ejecución de acciones en un entorno computacional o físico. En el desarrollo de este trabajo, se consideraron las señales electroencefalográficas o EEG (del inglés, *electroencephalogram*) debido a su naturaleza no invasiva y su capacidad para registrar la intención motriz del usuario en tiempo real. La integración de estos dispositivos con servicios en la nube facilita el procesamiento de grandes volúmenes de datos, lo que permite optimizar la capacidad de respuesta de los sistemas ante tareas de imaginación motriz.

1.1.1. Arquitectura funcional de un sistema BCI

El modelo operativo de una BCI inicia con una cadena de procesamiento compuesta por etapas secuenciales. En la fase inicial, se realiza la adquisición de señales mediante sensores electroencefalográficos colocados sobre el cuero cabelludo. Luego, los datos crudos se someten a procesos de preprocesamiento para la eliminación de artefactos, tales como parpadeos o movimientos musculares, mediante el uso de filtros digitales. Posteriormente, se realiza la extracción de características que permite identificar los componentes relevantes de la señal asociados a la intención del usuario. Finalmente, se implementan algoritmos de clasificación para traducir dichas características en comandos de control.

Imaginación motriz y ritmos sensorimotrices

La imaginación motriz se define como el proceso cognitivo en el que un individuo simula mentalmente una acción motora sin ejecutar un movimiento físico real

[2]. Este fenómeno produce cambios detectables en los ritmos sensoriales de la corteza cerebral, específicamente en las bandas de frecuencia mu (8-13 Hz) y beta (13-30 Hz).

1.1.2. Dispositivos de adquisición de señales EEG

La captura de la actividad eléctrica cerebral se realiza habitualmente mediante sistemas de EEG, estos se clasifican según su movilidad y el tipo de sensores empleados. En el ámbito de la investigación, se destacan dispositivos de grado médico y equipos portátiles diseñados para aplicaciones fuera del entorno clínico [3].

Aunque en este proyecto se utilizó un conjunto de datos o dataset previamente registrado, la comprensión de estos dispositivos resultó pertinente para el análisis de la calidad de la señal.

1.2. Estado del arte

La presente revisión del estado del arte tiene como objetivo identificar las metodologías dominantes en la clasificación de tareas de imaginación motriz mediante EEG. En los últimos años, el estudio de las BCI ha cobrado relevancia debido a la convergencia entre la neurociencia computacional y el aprendizaje profundo, lo que permite aprender directamente de las señales crudas, sin depender de métodos tradicionales de extracción de características como el patrón espacial común o CSP (del inglés, *Common Spatial Pattern*) [4].

Las redes neuronales convolucionales o CNN (del inglés, *Convolutional Neural Network*) constituyen una de las aproximaciones más utilizadas. Estas redes capturan patrones espaciales en las señales EEG y han demostrado un buen desempeño en la clasificación de tareas de imaginación motriz. Modelos como EEGNet introducen arquitecturas compactas que logran buenos resultados incluso con pocos datos de entrenamiento [5].

Por otra parte, las redes recurrentes, especialmente las de memoria a corto y largo plazo o LSTM (del inglés, *Long Short-Term Memory*), permiten modelar la dinámica temporal de las señales EEG. Estas arquitecturas capturan dependencias en el tiempo que resultan clave para identificar patrones asociados a la imaginación de movimiento. Estudios recientes reportan que modelos basados en LSTM alcanzan desempeños superiores frente a métodos tradicionales [6].

Asimismo, las arquitecturas híbridas que combinan CNN y LSTM han ganado relevancia. Estas combinaciones permiten integrar información espacial y temporal en un mismo modelo. Investigaciones muestran que este enfoque mejora la capacidad de generalización y aumenta la precisión en comparación con modelos individuales [6, 7].

En los trabajos más recientes, se han propuesto variantes más eficientes como redes convolucionales ligeras y modelos que operan en el dominio frecuencial. Estas propuestas buscan reducir la complejidad del modelo y mejorar el rendimiento con conjuntos de datos limitados, lo que representa un desafío común en aplicaciones de interfaces cerebro-computador [8].

La literatura técnica muestra un interés en el desplazamiento desde los métodos basados en la extracción manual de características, como los CSP, hacia sistemas de aprendizaje profundo. Mientras que los algoritmos tradicionales destacan por su baja carga computacional, las investigaciones recientes exponen que las arquitecturas híbridas logran una mayor robustez ante la variabilidad entre sujetos. Sin embargo, aún persisten retos relacionados con la variabilidad entre usuarios, la necesidad de grandes volúmenes de datos y la robustez en entornos reales [6].

En la tabla 1.1 se presenta la comparativa técnica de las arquitecturas y enfoques identificados en la revisión bibliográfica

TABLA 1.1. Comparativa de enfoques tecnológicos para la clasificación de imaginación motriz.

Enfoque	Técnicas	Ventajas	Limitaciones
Estadístico	CSP + SVM	Alta interpretabilidad y eficiencia en sistemas embebidos.	Sensible a artefactos y requiere calibración manual.
Redes Convolucionales	CNN (EEGNet)	Reducción de parámetros y extracción automática de rasgos.	Necesidad de grandes volúmenes de datos etiquetados.
Arquitectura Híbrida	CNN + LSTM	Modelado de dependencias temporales y espaciales.	Complejidad computacional elevada y riesgo de sobreajuste.

1.3. Motivación

El desarrollo de este proyecto se justificó en la necesidad de mejorar la precisión en la predicción de la intención de movimiento de un usuario a partir de señales EEG asociadas a tareas de imaginación motriz. A pesar de los avances en el procesamiento de señales biológicas, los métodos tradicionales presentan dificultades para adaptarse a la variabilidad de los ritmos sensorimotrices entre diferentes individuos, lo que limita su aplicación en entornos reales fuera del laboratorio [1, 9].

La implementación de modelos de inteligencia artificial avanzados permitió abordar la naturaleza no lineal y compleja de las señales de imaginación motriz, que presentan una alta variabilidad entre sujetos. Durante el análisis preliminar, se identificó que el procesamiento local en dispositivos embebidos restringía el uso de arquitecturas de aprendizaje profundo debido a las limitaciones de memoria y capacidad de cómputo de los sistemas portátiles. Por lo tanto, la integración de una infraestructura en la nube se presentó como una solución técnica viable para ejecutar modelos de alta complejidad sin comprometer la portabilidad ni la autonomía del sistema de adquisición.

Asimismo, la motivación de este trabajo residió en la creación de una arquitectura escalable que facilitara el entrenamiento continuo de los modelos. Al centralizar el procesamiento, se permitió la acumulación de datos para el refinamiento de los algoritmos, buscando una reducción significativa en el tiempo de calibración requerido para cada usuario. Esta aproximación tecnológica no solo optimizó el rendimiento predictivo, sino que también sentó las bases para interfaces cerebro-computador más robustas y eficientes en la práctica clínica y asistencial.

1.4. Objetivos y alcance

El desarrollo de este proyecto se orientó a la creación de una infraestructura tecnológica capaz de procesar y clasificar señales EEG en un entorno distribuido. A continuación, se presentan el objetivo general, los objetivos específicos y el alcance del proyecto.

1.4.1. Objetivo general

Establecer una base técnica que permitiera analizar patrones neuronales asociados a tareas de imaginación motriz, integrando modelos de inteligencia artificial y servicios en la nube para servir como referencia en futuros desarrollos de interfaces cerebro-computador.

1.4.2. Objetivos específicos

- Implementar una arquitectura de red neuronal capaz de identificar con precisión las intenciones de movimiento a partir de señales EEG.
- Diseñar un flujo de datos que integrara la adquisición de señales con el procesamiento remoto en una plataforma en la nube.
- Evaluar el desempeño del sistema mediante métricas de precisión y tiempo de respuesta en la clasificación de actividades de imaginación motriz.
- Documentar los procedimientos de preprocesamiento y entrenamiento para facilitar la replicabilidad del modelo en investigaciones posteriores.

1.4.3. Alcance

El alcance de este trabajo comprendió desde la selección y limpieza del conjunto de datos hasta el despliegue del modelo de inferencia en servidores remotos. Se limitó el estudio al análisis de tareas motoras binarias como el movimiento imaginado de mano izquierda y derecha, utilizando datasets de acceso público para garantizar la validación estadística de los resultados.

El sistema se diseñó para operar de forma asíncrona, priorizando la precisión del clasificador sobre la respuesta inmediata de baja latencia, estableciendo así un marco de trabajo robusto para la investigación de algoritmos complejos. No se incluyó en esta etapa el desarrollo de hardware de adquisición propio ni la implementación de biorretroalimentación en tiempo real para el usuario final.

Capítulo 2

Introducción Específica

En este capítulo se presentan los procedimientos técnicos para la obtención de señales EEG y los métodos de extracción de características aplicados en este trabajo. Asimismo, se describen las arquitecturas de redes neuronales orientadas a la clasificación de tareas de imaginación motriz.

2.1. Adquisición de datos

El conjunto de datos seleccionado para este trabajo provino de los registros originales publicados por los autores del estudio de Dreyer2023A, el cual documentó un protocolo de adquisición de señales de EEG diseñado para el estudio de la intención motora en sujetos sanos [10]. La recolección de la actividad cerebral se realizó mediante un sistema de alta resolución que permitió capturar las variaciones de potencial eléctrico en la corteza cerebral durante la ejecución de tareas mentales específicas, enfocadas en la discriminación de movimientos imaginados.

El protocolo experimental se fundamentó en un paradigma donde los participantes realizaron tareas de intención de movimiento de la mano izquierda y la mano derecha sin ejecución física. Cada ensayo siguió una secuencia temporal estricta que inició con una fase de advertencia, seguida de una señal visual o *cue* (del inglés, *visual cue*) que indicó la dirección del movimiento imaginado. Los sujetos mantuvieron la actividad mental durante un intervalo de cuatro segundos, lo que permitió el registro de los ritmos sensorimotrices asociados a la planificación motora. Las condiciones del experimento se mantuvieron controladas en una habitación con aislamiento acústico para garantizar la repetibilidad de las mediciones.

2.1.1. Configuración técnica y estructura del conjunto de datos

La captura de las señales se realizó mediante una distribución de 64 electrodos activos dispuestos según el sistema internacional 10-20 como puede observarse en la figura 2.1, ubicados sobre las áreas motoras y somatosensoriales. Esta disposición facilita la detección de los fenómenos de desincronización relacionada con eventos, los cuales resultan fundamentales para la clasificación de las tareas motrices. Los datos se digitalizaron con una frecuencia de muestreo de 500 Hz y se aplicó un filtro de línea de 50 Hz para reducir la interferencia eléctrica.

El conjunto de datos final se estructuró en registros correspondientes a 60 participantes sanos. Gracias a la integración con la biblioteca MOABB, se logró una




FIGURA 2.1. Imagen tomada de la página oficial del procesador¹.

segmentación uniforme de los ensayos, permitiendo que cada archivo incluyera las etiquetas de clase para la mano izquierda y la mano derecha de manera consistente. Esta organización facilitó el tratamiento digital de la información en la infraestructura en la nube, asegurando la integridad de las señales antes del proceso de entrenamiento de los modelos.

En la tabla 2.1 se presentan las especificaciones técnicas que caracterizaron al conjunto de datos utilizado en este trabajo, destacando la cantidad de participantes, la duración de cada ensayo, el número de ensayos por clase y la calidad de las señales obtenidas. Esta información es crucial para comprender el contexto en el que se desarrolló el modelo de clasificación de imaginación motriz y para evaluar su desempeño en función de las características del conjunto de datos.

TABLA 2.1. Especificaciones técnicas del conjunto de datos Dreyer2023A.

Parámetro	Valor
Número de sujetos	60
Número de canales EEG	27
Número de clases de imaginación motriz	2 (mano izquierda, mano derecha)
Frecuencia de muestreo	500 Hz
Duración de ensayo	5 s
Runs por sujeto	6
Ensayos por clase por sujeto	20

2.2. Métodos tradicionales para EEG y extracción automática de características

Tradicionalmente, la decodificación de la imaginación motriz se fundamentó en el uso de algoritmos de aprendizaje automático o Machine Learning combinados con una etapa crítica de ingeniería de rasgos manual.

El método tradicional generalizado consiste en la aplicación de CSP. Esta técnica se basa en la descomposición de las señales para maximizar la varianza entre clases, facilitando la separación de los estados mentales de movimiento [11]. Tras la extracción de estos patrones, se emplearon clasificadores de baja complejidad como el análisis discriminante lineal o LDA (del inglés, *Linear Discriminant Analysis*) y las máquinas de vectores de soporte o SVM (del inglés, *Support Vector Machines*). Si bien estos métodos demostraron eficacia en entornos controlados, presentan una alta sensibilidad a la colocación de los electrodos y requieren un ajuste experto de las bandas de frecuencia para cada sujeto.

Frente a estas limitaciones, el avance hacia el aprendizaje profundo o Deep Learning permite el desarrollo de modelos que ejecutan la extracción automática de características. A diferencia de los esquemas clásicos, estas arquitecturas aprenden representaciones jerárquicas directamente de los datos crudos. Sin embargo, en este trabajo se identificó que la calidad de la adquisición sigue siendo un factor determinante para el éxito de estos modelos. Una configuración deficiente en la toma de muestras o una mala colocación de los sensores introducen artefactos que las redes neuronales pueden interpretar erróneamente como patrones fisiológicos, afectando la robustez de la predicción final. Por lo tanto, la capacidad de los modelos profundos para identificar rasgos imperceptibles no exime al sistema de la necesidad de contar con señales de alta fidelidad.

En la tabla 2.2 se presenta una comparación entre los métodos tradicionales de procesamiento de EEG y las técnicas de aprendizaje profundo, destacando sus características, ventajas y limitaciones en el contexto del análisis de señales EEG para la clasificación de tareas de imaginación motriz.

2.3. Arquitecturas de redes neuronales para EEG en imaginación motriz

Las CNN se consolidaron como una de las herramientas más eficaces para la extracción de características. Mediante el uso de filtros de convolución, estas redes permitieron identificar patrones de activación en regiones específicas de la corteza motora, simulando de manera automática el comportamiento de los filtros espaciales tradicionales. En este trabajo, el uso de las CNN facilitó la detección de cambios en la amplitud de los ritmos sensorimotrices asociados a la intención de movimiento de las extremidades.

Por otro lado, para el análisis de la dinámica temporal de las señales EEG, se exploraron las redes neuronales recurrentes o RNN (del inglés, *Recurrent Neural Networks*), específicamente las unidades de memoria de largo corto plazo o LSTM (del inglés, *Long Short-Term Memory*) y las unidades recurrentes calificadas o GRU (del inglés, *Gated Recurrent Units*). Estas arquitecturas permitieron modelar la evolución de la señal a lo largo del tiempo, utilizando mecanismos de puertas para retener información relevante y descartar el ruido transitorio. Mientras

TABLA 2.2. Comparación entre métodos tradicionales y modelos de aprendizaje profundo para el análisis de EEG.

Característica	Métodos Tradicionales (CSP, SVM, LDA)	Aprendizaje Profundo (CNN, EEGNet)
Extracción de rasgos	Manual y basada en conocimiento experto.	Automática a partir de los datos de entrada.
Sensibilidad al ruido	Muy alta requiere filtros manuales estrictos.	Moderada, puede aprender a filtrar, pero depende de la calidad del dato.
Manejo de datos	Requiere segmentación y filtrado previo.	Capacidad de procesar señales con preprocesamiento mínimo.
Rendimiento	Limitado ante señales no estacionarias.	Mayor robustez y escalabilidad con grandes volúmenes de datos.
Dependencia	Alta dependencia de la calibración por sujeto.	Potencial para el aprendizaje transferido entre sujetos.

que las LSTM emplearon una estructura compleja para gestionar la memoria a largo plazo, las GRU ofrecieron una alternativa más eficiente en términos computacionales, manteniendo un rendimiento competitivo en la clasificación de series temporales de EEG.

Por último, este trabajo consideró enfoques híbridos que integran las ventajas de ambos modelos. Las arquitecturas de tipo CNN-LSTM permitieron realizar una extracción de rasgos espaciales en las primeras capas para luego procesar la secuencia temporal resultante, con el fin de optimizar la capacidad del sistema para reconocer la intención del usuario. Esta combinación resultó estratégica para manejar la alta dimensionalidad de los datos del conjunto de datos Dreyer2023A, asegurando una representación robusta antes de la etapa de clasificación final.

El enfoque híbrido y las arquitecturas de redes neuronales aplicadas al análisis de señales EEG, se puede observar en la figura 2.2, donde se ilustra la estructura general de cada modelo y su aplicación específica en el contexto de la clasificación de tareas de imaginación motriz.

En la tabla 2.3 se presenta una comparación técnica entre las arquitecturas de redes neuronales aplicadas al análisis de señales EEG, se destaca las características, ventajas y limitaciones en el contexto de la clasificación de tareas de imaginación motriz. Esta comparación proporciona una visión integral de cómo cada enfoque contribuye al procesamiento de las señales EEG y a la mejora del rendimiento en la decodificación de la intención motora.




FIGURA 2.2. Imagen generada por inteligencia artificial

TABLA 2.3. Comparación entre arquitecturas CNN, LSTM y CNN-LSTM en EEG.

Característica	Métodos Tradicionales (CSP, SVM, LDA)	Aprendizaje Profundo (CNN, EEGNet)	Aprendizaje Profundo (CNN, EEGNet)
CNN	Excelente extracción de rasgos espaciales y locales.	No captura eficientemente dependencias temporales largas.	Identificación de patrones en la distribución de electrodos.
LSTM / GRU	Especializadas en modelado de secuencias y series temporales.	Alto costo computacional y riesgo de desvanecimiento de gradiente.	Análisis de la evolución temporal de los ritmos cerebrales.
CNN-LSTM	Combina el aprendizaje de rasgos espaciales y temporales.	Mayor complejidad en el entrenamiento y ajuste de parámetros.	Clasificación integral de ensayos de imaginación motriz.

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno `lstlisting` con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
  las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código [3.1](#):

```
1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ACTUATOR_NUMBER 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
8 state_t actuatorState[MAX_ACTUATOR_NUMBER]; //ON or OFF
9
10 void vControl() {
11
12     initGlobalVariables();
13
14     period = 500 ms;
15
16     while(1) {
17
18         ticks = xTaskGetTickCount();
19
20         updateSensors();
21
22         updateAlarms();
23
24         controlActuators();
25
26         vTaskDelayUntil(&ticks, period);
27     }
```

28 }

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Jonathan R. Wolpaw et al. «Brain-computer interfaces for communication and control». En: *Clinical Neurophysiology* 113.6 (2002), págs. 767-791.
- [2] Gert Pfurtscheller y Christa Neuper. «Motor imagery and direct brain-computer communication». En: *Proceedings of the IEEE* 89.7 (2001), págs. 1123-1134.
- [3] Alexander J. Casson et al. «Wearable electroencephalography». En: *IEEE Engineering in Medicine and Biology Magazine* 29.3 (2010), págs. 44-56.
- [4] Robin Tibor Schirrmeister et al. «Deep learning with convolutional neural networks for EEG decoding and visualization». En: *Human Brain Mapping* 38.11 (2017), págs. 5391-5420.
- [5] Vernon J. Lawhern et al. «EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 15.5 (2018).
- [6] Yannick Roy et al. «Deep learning-based electroencephalography analysis: a systematic review». En: *Journal of Neural Engineering* 16.5 (2019).
- [7] Pouya Bashivan et al. «Learning representations from EEG with deep recurrent-convolutional neural networks». En: *arXiv preprint arXiv:1511.06448* (2015).
- [8] Alexander Craik, Yongtian He y Jose L. Contreras-Vidal. «Deep learning for electroencephalogram (EEG) classification tasks: a review». En: *Journal of Neural Engineering* 16.3 (2019).
- [9] Fabien Lotte et al. «A review of classification algorithms for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 4.2 (2007).
- [10] Alaric M. Dreyer et al. «A large electroencephalography dataset for the study of motor imagery». En: *Scientific Data* 10.1 (2023), pág. 583. DOI: [10.1038/s41597-023-02445-z](https://doi.org/10.1038/s41597-023-02445-z).
- [11] Jaime Riascos, Marta Molinas y Fabien Lotte. «Machine Learning Methods for BCI: challenges, pitfalls and promises». En: *ESANN 2024-European symposium on artificial neural networks, computational intelligence and machine learning*. 2024.