

Interfaces cerebro-cloud para la predicción de actividades de imaginación motriz

Ing. Freddy Julian Riascos Salas

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Jaime Andrés Riascos Salas (Potsdam Embodied Cognition Group)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Pasto, junio de 2026

Resumen

En la presente memoria se describe el desarrollo de un sistema de inteligencia artificial enfocado en la predicción de tareas de imaginación motriz usando señales de electroencefalografía. Este trabajo busca dejar una base técnica para el desarrollo de sistemas de interacción cerebro-computador en imaginación motriz para predecir la intención de movimiento en usuarios.

Para su implementación fueron necesarios los conocimientos adquiridos en la especialización incluidos procesamiento y análisis de datos, aprendizaje automático, redes neuronales y operaciones.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Interfaces cerebro-computador	1
1.1.1. Arquitectura funcional de un sistema BCI	1
1.1.2. Dispositivos de adquisición de señales EEG	2
1.2. Estado del arte	2
1.3. Motivación	3
1.4. Objetivos y alcance	4
1.4.1. Objetivo general	4
1.4.2. Objetivos específicos	4
1.4.3. Alcance	4
2. Introducción específica	5
2.1. Adquisición de datos	5
2.1.1. Configuración técnica y estructura del conjunto de datos	5
2.2. Métodos tradicionales en EEG y extracción automática de características	7
2.3. Arquitecturas de redes neuronales para EEG en tareas de imaginación motriz	8
3. Diseño e implementación	11
3.1. Arquitectura del sistema	11
3.2. Preparación y preprocesamiento de los datos	12
3.2.1. Preparación de los datos	12
3.2.2. Preprocesamiento de los datos	13
3.2.3. Segmentación de los datos	13
3.3. Desarrollo de modelos	14
3.3.1. Modelo basado en redes convolucionales	15
3.3.2. Modelo basado en redes neuronales recurrentes	15
3.3.3. Modelo híbrido basado en CNN-LSTM	16
3.4. Configuración del entrenamiento	17
3.5. Protocolo de evaluación	19
3.6. Despliegue del modelo	20
4. Ensayos y resultados	23
4.1. Pruebas funcionales del hardware	23
5. Conclusiones	25
5.1. Conclusiones generales	25
5.2. Próximos pasos	25
Bibliografía	27

Índice de figuras

2.1. Distribución de electrodos según el sistema 10-20 utilizado en la adquisición de señales EEG.	6
2.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.	8
3.1. Diagrama de la arquitectura general del sistema.	12
3.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.	22

Índice de tablas

1.1. Comparativa de enfoques	3
2.1. dataset dreyer	6
2.2. Comparación entre modelos	7
2.3. Comparación entre arquitecturas	9
3.1. Parámetros Dataset	14
3.2. Configuración de las arquitecturas implementadas	17
3.3. Hiperparámetros utilizados durante el entrenamiento	19
3.4. Métricas utilizadas para la evaluación de modelos EEG en tareas de imaginación motriz	20
3.5. Estimación de costos de despliegue e inferencia del sistema EEG . .	21

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presentan los fundamentos de las tecnologías de interfaz cerebro-computador y se describe el estado actual de la investigación en el área. Asimismo, se exponen la motivación, los objetivos y el alcance definidos para el desarrollo del trabajo.

1.1. Interfaces cerebro-computador

Las interfaces cerebro-computador o BCI (del inglés, *Brain-Computer Interface*) se definen como sistemas que establecen una vía de comunicación directa entre el cerebro humano y un dispositivo externo [1]. Estos sistemas permiten la traducción de patrones de actividad cerebral en comandos de control sin la intervención de las vías periféricas neuromusculares tradicionales.

El funcionamiento de una BCI se fundamentó en la adquisición de señales bioeléctricas, su procesamiento digital y la posterior ejecución de acciones en un entorno computacional o físico. En el desarrollo de este trabajo, se consideraron las señales electroencefalográficas o EEG (del inglés, *electroencephalogram*) debido a su naturaleza no invasiva y su capacidad para registrar la intención motriz del usuario en tiempo real. La integración de estos dispositivos con servicios en la nube facilita el procesamiento de grandes volúmenes de datos, lo que permite optimizar la capacidad de respuesta de los sistemas ante tareas de imaginación motriz.

1.1.1. Arquitectura funcional de un sistema BCI

El modelo operativo de una BCI inicia con una cadena de procesamiento compuesta por etapas secuenciales. En la fase inicial, se realiza la adquisición de señales mediante sensores electroencefalográficos colocados sobre el cuero cabelludo. Luego, los datos crudos se someten a procesos de preprocesamiento para la eliminación de artefactos, tales como parpadeos o movimientos musculares, mediante el uso de filtros digitales. Posteriormente, se realiza la extracción de características que permite identificar los componentes relevantes de la señal asociados a la intención del usuario. Finalmente, se implementan algoritmos de clasificación para traducir dichas características en comandos de control.

En este contexto, la imaginación motriz se define como el proceso cognitivo en el que un individuo simula mentalmente una acción motora sin ejecutar un movimiento físico real [2]. Este fenómeno produce cambios detectables en los ritmos

sensorimotrices de la corteza cerebral, específicamente en las bandas de frecuencia mu (8–13 Hz) y beta (13–30 Hz), que constituyen la base fisiológica para la decodificación de la intención de movimiento en sistemas BCI.

1.1.2. Dispositivos de adquisición de señales EEG

La captura de la actividad eléctrica cerebral se realiza habitualmente mediante sistemas de EEG. Estos se clasifican según su movilidad y el tipo de sensores empleados. En el ámbito de la investigación, se destacan dispositivos de grado médico y equipos portátiles diseñados para aplicaciones fuera del entorno clínico, estos han sido ampliamente abordados en la literatura científica[3]. Aunque en este trabajo se utilizó un conjunto de datos o dataset previamente registrado, la comprensión de estos dispositivos resultó pertinente para el análisis de la calidad de la señal.

1.2. Estado del arte

La presente revisión del estado del arte tiene como objetivo identificar las metodologías dominantes en la clasificación de tareas de imaginación motriz mediante EEG. En los últimos años, el estudio de las BCI ha cobrado relevancia debido a la convergencia entre la neurociencia computacional y el aprendizaje profundo, lo que permite aprender directamente de las señales crudas, sin depender de métodos tradicionales de extracción de características como el patrón espacial común o CSP (del inglés, *Common Spatial Pattern*) [4].

Las redes neuronales convolucionales o CNN (del inglés, *Convolutional Neural Network*) constituyen una de las aproximaciones más utilizadas. Estas redes capturan patrones espaciales en las señales EEG y han demostrado un buen desempeño en la clasificación de tareas de imaginación motriz. Modelos como EEGNet introducen arquitecturas compactas que logran buenos resultados incluso con pocos datos de entrenamiento [5].

Por otra parte, las redes recurrentes, especialmente las de memoria a corto y largo plazo o LSTM (del inglés, *Long Short-Term Memory*), permiten modelar la dinámica temporal de las señales EEG. Estas arquitecturas capturan dependencias en el tiempo que resultan clave para identificar patrones asociados a la imaginación de movimiento. Estudios recientes reportan que modelos basados en LSTM alcanzan desempeños superiores frente a métodos tradicionales [6].

Asimismo, las arquitecturas híbridas que combinan CNN y LSTM han ganado relevancia. Estas combinaciones permiten integrar información espacial y temporal en un mismo modelo. Investigaciones muestran que este enfoque mejora la capacidad de generalización y aumenta la precisión en comparación con modelos individuales [6, 7].

En los trabajos más recientes, se han propuesto variantes más eficientes como redes convolucionales ligeras y modelos que operan en el dominio frecuencial. Estas propuestas buscan reducir la complejidad del modelo y mejorar el rendimiento con conjuntos de datos limitados, lo que representa un desafío común en aplicaciones de interfaces cerebro-computador [8].

La literatura técnica muestra un interés en el desplazamiento desde los métodos basados en la extracción manual de características, como los CSP, hacia sistemas

de aprendizaje profundo. Mientras que los algoritmos tradicionales destacan por su baja carga computacional, las investigaciones recientes exponen que las arquitecturas híbridas logran una mayor robustez ante la variabilidad entre sujetos. Sin embargo, aún persisten retos relacionados con la variabilidad entre usuarios, la necesidad de grandes volúmenes de datos y la robustez en entornos reales [6].

En la tabla 1.1 se presenta la comparativa técnica de las arquitecturas y enfoques identificados en la revisión bibliográfica.

TABLA 1.1. Comparativa de enfoques tecnológicos para la clasificación de imaginación motriz.

Enfoque	Técnicas	Ventajas	Limitaciones
Estadístico	CSP + SVM	Alta interpretabilidad y eficiencia en sistemas embebidos.	Sensible a artefactos y requiere calibración manual.
Redes Convolucionales	CNN (EEGNet)	Reducción de parámetros y extracción automática de rasgos.	Necesidad de grandes volúmenes de datos etiquetados.
Arquitectura Híbrida	CNN + LSTM	Modelado de dependencias temporales y espaciales.	Complejidad computacional elevada y riesgo de sobreajuste.

1.3. Motivación

El desarrollo de este trabajo se justificó en la necesidad de mejorar la precisión en la predicción de la intención de movimiento de un usuario a partir de señales EEG asociadas a tareas de imaginación motriz. A pesar de los avances en el procesamiento de señales biológicas, los métodos tradicionales presentan dificultades para adaptarse a la variabilidad de los ritmos sensorimotrices entre diferentes individuos, lo que limita su aplicación en entornos reales fuera del laboratorio y representa un desafío significativo para la generalización en sistemas EEG [1, 9].

La implementación de modelos de inteligencia artificial avanzados permitió abordar la naturaleza no lineal y compleja de las señales de imaginación motriz, que presentan una alta variabilidad entre sujetos. Durante el análisis preliminar, se identificó que el procesamiento local en dispositivos embebidos restringía el uso de arquitecturas de aprendizaje profundo debido a las limitaciones de memoria y capacidad de cómputo de los sistemas portátiles. Por lo tanto, la integración de una infraestructura en la nube se presentó como una solución técnica viable para ejecutar modelos de alta complejidad sin comprometer la portabilidad ni la autonomía del sistema de adquisición.

Asimismo, la motivación de este trabajo residió en la creación de una arquitectura escalable que facilitara el entrenamiento continuo de los modelos. Al centralizar el procesamiento, se permitió la acumulación de datos para el refinamiento de los algoritmos, que busca una reducción significativa en el tiempo de calibración requerido para cada usuario. Esta aproximación tecnológica no solo optimizó el rendimiento predictivo, sino que también sentó las bases para interfaces cerebro-computador más robustas y eficientes en la práctica clínica y asistencial.

1.4. Objetivos y alcance

El desarrollo de este trabajo se orientó a la creación de una infraestructura tecnológica capaz de procesar y clasificar señales EEG en un entorno distribuido. A continuación, se presentan el objetivo general, los objetivos específicos y el alcance del trabajo.

1.4.1. Objetivo general

Establecer una base técnica que permitiera analizar patrones neuronales asociados a tareas de imaginación motriz, que integra modelos de inteligencia artificial y servicios en la nube para servir como referencia en futuros desarrollos de interfaces cerebro-computador.

1.4.2. Objetivos específicos

Para cumplir con el objetivo general, se plantearon los siguientes objetivos específicos:

- Implementar una arquitectura de red neuronal capaz de identificar con precisión las intenciones de movimiento a partir de señales EEG.
- Diseñar un flujo de datos que integrara la adquisición de señales con el procesamiento remoto en una plataforma en la nube.
- Evaluar el desempeño del sistema mediante métricas de precisión y tiempo de respuesta en la clasificación de actividades de imaginación motriz.
- Documentar los procedimientos de preprocesamiento y entrenamiento para facilitar la replicabilidad del modelo en investigaciones posteriores.

1.4.3. Alcance

El alcance de este trabajo comprendió desde la selección y limpieza del conjunto de datos hasta el despliegue del modelo de inferencia en servidores remotos. Se limitó el estudio al análisis de tareas motoras binarias como el movimiento imaginado de la mano izquierda y la derecha. Se utilizan datasets de acceso público para garantizar la validación estadística de los resultados.

El sistema se diseñó para operar de forma asíncrona, que prioriza la precisión del clasificador sobre la respuesta inmediata de baja latencia. Se establece así un marco de trabajo robusto para la investigación de algoritmos complejos. No se incluyó en esta etapa el desarrollo de hardware de adquisición propio ni la implementación de biorretroalimentación en tiempo real para el usuario final.

Capítulo 2

Introducción específica

En este capítulo se presentan los procedimientos técnicos para la obtención de señales EEG y los métodos de extracción de características aplicados en este trabajo. Asimismo, se describen las arquitecturas de redes neuronales orientadas a la clasificación de tareas de imaginación motriz.

2.1. Adquisición de datos

El conjunto de datos seleccionado para este trabajo provino de los registros originales publicados por los autores del estudio Dreyer2023A [10], que presenta una base de datos de señales EEG orientada al análisis de la intención motora en sujetos sanos.

Es importante destacar que la adquisición de las señales EEG y el diseño del protocolo experimental fueron realizados por los autores del estudio original. En este trabajo no se llevó a cabo la recolección de datos, sino que se utilizó este conjunto de datos público como base para el desarrollo de los procesos de análisis, modelado y clasificación.

En el estudio original, la recolección de la actividad cerebral se realiza mediante un sistema de alta resolución que permite capturar las variaciones de potencial eléctrico en la corteza cerebral durante la ejecución de tareas mentales específicas, enfocadas en la discriminación de movimientos imaginados.

El protocolo experimental se fundamenta en un paradigma en el que los participantes realizan tareas de intención de movimiento de la mano izquierda y la mano derecha sin ejecución física. Cada ensayo sigue una secuencia temporal estricta que inicia con una fase de advertencia, seguida de una señal visual que indica la dirección del movimiento imaginado. Los sujetos mantienen la actividad mental durante un intervalo de cuatro segundos, lo que permite el registro de los ritmos sensorimotrices asociados a la planificación motora. Las condiciones del experimento se mantienen controladas en una habitación con aislamiento acústico para garantizar la repetibilidad de las mediciones.

2.1.1. Configuración técnica y estructura del conjunto de datos

En el estudio original, la captura de las señales la realizan mediante una distribución de 64 electrodos activos dispuestos según el sistema internacional 10-20, como puede observarse en la figura 2.1; estos se ubican sobre las áreas motoras y somatosensoriales. Esta disposición facilita la detección de los fenómenos de desincronización relacionada con eventos, que resultan fundamentales para la

2.2. Métodos tradicionales en EEG y extracción automática de características

Tradicionalmente, la decodificación de la imaginación motriz se basa en algoritmos de aprendizaje automático combinados con una etapa de ingeniería de rasgos manual. El enfoque más común utiliza CSP, técnica que descompone las señales para maximizar la varianza entre clases y facilitar la separación de estados mentales [11]. A partir de estos patrones, se emplean clasificadores como LDA (del inglés, *Linear Discriminant Analysis*) y SVM (del inglés, *Support Vector Machines*). Aunque efectivos en entornos controlados, estos métodos son sensibles a la colocación de electrodos y requieren ajuste experto de las bandas de frecuencia por sujeto.

Frente a estas limitaciones, el avance hacia el aprendizaje profundo o Deep Learning ha permitido el desarrollo de modelos capaces de realizar la extracción automática de características. A diferencia de los esquemas clásicos, estas arquitecturas aprenden representaciones jerárquicas directamente a partir de los datos crudos, y se reduce la necesidad de una ingeniería de rasgos manual.

Sin embargo, diversos estudios han señalado que la calidad de la adquisición de las señales EEG continúa siendo un factor determinante en el desempeño de estos modelos. Una configuración deficiente en la toma de muestras o una inadecuada colocación de los sensores puede introducir artefactos que las redes neuronales interpretan erróneamente como patrones fisiológicos, lo que afecta la robustez de la predicción. Por lo tanto, aunque los modelos de aprendizaje profundo contengan la capacidad de identificar características complejas, su desempeño depende en gran medida de la calidad y fidelidad de las señales de entrada.

En la tabla 2.2 se presenta una comparación entre los métodos tradicionales de procesamiento de EEG y las técnicas de aprendizaje profundo. Estas destacan sus características, ventajas y limitaciones en el contexto del análisis de señales EEG para la clasificación de tareas de imaginación motriz.

TABLA 2.2. Comparación entre métodos tradicionales y modelos de aprendizaje profundo para el análisis de EEG.

Característica	Métodos Tradicionales (CSP, SVM, LDA)	Aprendizaje Profundo (CNN, EEGNet)
Extracción de rasgos	Manual y basada en conocimiento experto.	Automática a partir de los datos de entrada.
Sensibilidad al ruido	Muy alta, requiere filtros manuales estrictos.	Moderada, depende de la calidad del dato.
Manejo de datos	Requiere segmentación y filtrado previo.	Procesamiento con preprocesamiento mínimo.
Rendimiento	Limitado ante señales no estacionarias.	Mayor robustez y escalabilidad.
Dependencia	Alta dependencia de calibración por sujeto.	Posibilidad de aprendizaje transferido.

2.3. Arquitecturas de redes neuronales para EEG en tareas de imaginación motriz

Las CNN se consolidan como una de las herramientas más eficaces para la extracción de características. Mediante el uso de filtros de convolución, estas redes permiten identificar patrones de activación en regiones específicas de la corteza motora, que simula de manera automática el comportamiento de los filtros espaciales tradicionales. Por ello, el uso de las CNN facilita la detección de cambios en la amplitud de los ritmos sensorimotrices asociados a la intención de movimiento de las extremidades.

Por otro lado, para el análisis de la dinámica temporal de las señales EEG, las redes neuronales recurrentes o RNN (del inglés, *Recurrent Neural Networks*), específicamente las unidades de memoria de largo corto plazo o LSTM (del inglés, *Long Short-Term Memory*) y las unidades recurrentes calificadas o GRU (del inglés, *Gated Recurrent Units*) permiten modelar la evolución de la señal a lo largo del tiempo; estas utilizan mecanismos de puertas para retener información relevante y descartar el ruido transitorio. Mientras que las LSTM emplean una estructura compleja para gestionar la memoria a largo plazo, las GRU ofrecen una alternativa más eficiente en términos computacionales, que mantiene un rendimiento competitivo en la clasificación de series temporales de EEG.

Por último, los enfoques híbridos han sido ampliamente utilizados para integrar las ventajas de distintos modelos en el análisis de señales EEG. En particular, las arquitecturas de tipo CNN-LSTM combinan la capacidad de las redes convolucionales para extraer características espaciales con la habilidad de las redes recurrentes para modelar dependencias temporales [12].

El enfoque híbrido y las arquitecturas de redes neuronales para el análisis de señales EEG se muestran en la figura 2.2, en la que se ilustra la estructura de cada modelo y su aplicación en la clasificación de tareas de imaginación motriz.




FIGURA 2.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.

En este tipo de arquitecturas, las capas convolucionales permiten identificar patrones relevantes en la distribución espacial de los electrodos, mientras que las capas recurrentes procesan la evolución temporal de dichas características. Esta combinación resulta adecuada para el manejo de la alta dimensionalidad de las señales EEG, que facilita la construcción de representaciones robustas previas a la etapa de clasificación.

En la tabla 2.3 se presenta una comparación técnica entre las arquitecturas de redes neuronales aplicadas al análisis de señales EEG, y se destacan las características, ventajas y limitaciones en el contexto de la clasificación de tareas de imaginación motriz. Esta comparación proporciona una visión integral de cómo cada enfoque contribuye al procesamiento de las señales EEG y a la mejora del rendimiento en la decodificación de la intención motora.

TABLA 2.3. Comparación entre arquitecturas CNN, LSTM y CNN-LSTM aplicadas al análisis de señales EEG.

Característica	CNN	LSTM / GRU	CNN-LSTM
Tipo de procesamiento	Espacial (filtros convolucionales)	Temporal (modelado secuencial)	Espacial + temporal combinado
Extracción de características	Automática en dominios espaciales locales	Basada en dependencias temporales	Extracción jerárquica espacio-temporal
Manejo de dependencias temporales	Limitado	Alto (memoria de corto y largo plazo)	Alto (integrado con características espaciales)
Complejidad computacional	Moderada	Alta	Alta
Robustez frente a ruido	Moderada	Moderada	Alta (por integración de representaciones)
Ventaja principal	Detección de patrones espaciales en electrodos	Modelado de dinámica temporal de la señal	Captura conjunta de patrones espaciales y temporales
Limitación principal	No modela secuencias largas	Alto costo y entrenamiento más complejo	Mayor complejidad y necesidad de ajuste fino
Aplicación en EEG	Identificación de activación cortical localizada	Análisis de evolución temporal de ritmos cerebrales	Clasificación integral de tareas de imaginación motriz

Capítulo 3

Diseño e implementación

En este capítulo se describen las etapas de diseño y el ajuste del sistema orientado a la clasificación de tareas de imaginación motriz. En las siguientes secciones se detallan la arquitectura del sistema, el tratamiento de los datos de origen, el desarrollo y entrenamiento de los modelos de aprendizaje profundo, así como el protocolo de evaluación y el despliegue final en la infraestructura de la nube.

3.1. Arquitectura del sistema

En esta sección se describe la arquitectura general del sistema que se utilizó para la predicción de tareas de imaginación motriz a partir de EEG.

El sistema se estructuró como un flujo secuencial compuesto por etapas de preparación de datos, preprocesamiento, extracción de características, inferencia mediante modelos de aprendizaje profundo y despliegue en infraestructura cloud. Este enfoque permitió integrar el procesamiento de señales EEG con servicios distribuidos, lo que facilitó la escalabilidad y la eficiencia en la ejecución de los modelos.

La fuente de datos correspondió al conjunto de datos Dreyer2023A [10]. Este contiene registros de señales EEG asociados a tareas de imaginación motriz. Dicho conjunto fue utilizado como base para el entrenamiento y evaluación de los modelos, sin realizar procesos de adquisición directa de señales.

Luego, se implementó una etapa de preprocesamiento orientada a mejorar la relación entre la señal y el ruido. En esta fase se aplicaron técnicas de filtrado y segmentación, con el fin de aislar ventanas relevantes para el análisis. Este procedimiento permitió reducir la variabilidad inherente a las señales EEG y facilitar el aprendizaje de patrones discriminativos.

La extracción de características se abordó mediante arquitecturas de redes neuronales, que permitieron modelar dependencias espaciales y temporales presentes en las señales. Se consideraron enfoques híbridos capaces de capturar correlaciones entre canales y dinámicas temporales, lo que resulta fundamental en tareas de imaginación motriz [12].

El módulo de inferencia se diseñó para recibir las representaciones procesadas y generar una predicción de la tarea imaginada. Este módulo se integró con un servicio web, que permitió exponer la funcionalidad del modelo por medio de una API RESTful. De esta manera, se facilitaría la interacción con aplicaciones externas y la posibilidad de realizar predicciones en tiempo real.

A continuación, se presenta la arquitectura general del sistema propuesto en la figura 3.1, en la que se ilustran las etapas principales del flujo de procesamiento y su integración dentro del entorno cloud.




FIGURA 3.1. Diagrama de la arquitectura general del sistema.

Finalmente, el sistema se desplegó bajo un paradigma cloud, que permitió desacoplar el procesamiento intensivo del entorno local. Esta arquitectura facilitó la implementación de una interfaz cerebro-computador cloud, en la que las señales fueron procesadas de manera remota para la generación de resultados.

La arquitectura descrita estableció un flujo completo desde la preparación de los datos hasta la obtención de predicciones, lo que garantizó modularidad, escalabilidad y capacidad de integración con aplicaciones externas.

3.2. Preparación y preprocesamiento de los datos

En esta sección se describen los métodos aplicados a las señales EEG antes del entrenamiento de los modelos, estos incluyen las etapas de preparación, preprocesamiento, filtrado, segmentación, transformación y estandarización de los datos.

3.2.1. Preparación de los datos

En la etapa de preparación, se realizó la carga de los registros EEG considerando su organización estructurada por sujetos, sesiones y ensayos, conforme a la definición del conjunto de datos Dreyer2023A descrito en [10]. Este conjunto incluye múltiples participantes sometidos a experimentos de imaginación motriz de mano izquierda y derecha, con un número significativo de ensayos por sesión, lo que permitió disponer de un volumen amplio de datos para el entrenamiento de los modelos. Por medio de la interfaz de MOABB (del inglés, *Mother Of All BCI Benchmarks*), se accedió a los datos en un formato estandarizado basado en eventos, lo que facilitó la manipulación de las señales y su integración en el flujo de procesamiento.

Después, se identificaron los eventos asociados a cada tarea de imaginación motriz, que correspondían a etiquetas discretas como mano izquierda y mano derecha dentro del paradigma de clasificación binaria. Estos eventos permitieron segmentar las señales continuas en ensayos individuales alineados temporalmente con los estímulos experimentales. Cada ensayo representó una instancia etiquetada del conjunto de datos, lo que permitió estructurar la información en un esquema supervisado ideal para el entrenamiento de los modelos.

Por otra parte, se consideró la consistencia en la organización de los canales EEG y la sincronización temporal de las señales, lo que garantizó que cada muestra mantuviera la correspondencia entre dimensiones espaciales y temporales. Este proceso permitió transformar los datos originales en una representación homogénea, lo que facilitó su posterior procesamiento y aseguró la compatibilidad en términos de entradas estructuradas y uniformes con los modelos.

3.2.2. Preprocesamiento de los datos

En la fase de preprocesamiento, se aplicó un filtrado de las señales EEG con el objetivo de mejorar la relación señal y ruido para resaltar los componentes relevantes para la tarea de clasificación. Para eso, se empleó un filtro pasa banda en el rango de 8 a 30 Hz, se considera que este intervalo abarca las bandas μ (aproximadamente 8–13 Hz) y β (13–30 Hz), que están estrechamente relacionadas con la actividad cortical asociada a la imaginación motriz [2, 12]. Estas bandas presentan patrones característicos de desincronización y sincronización relacionados con la ejecución o imaginación de movimientos, lo que las convierte en una fuente relevante de información discriminativa.

El filtrado permitió atenuar componentes de muy baja frecuencia, asociadas a derivas de la señal y artefactos fisiológicos como la actividad electrodermal, así como reducir el ruido de alta frecuencia proveniente de interferencias externas o actividad muscular no deseada. De esta manera, se preservó la información espectral de interés mientras se eliminaban componentes irrelevantes para la tarea.

De igual forma, este proceso contribuyó a estabilizar la señal y a reducir la variabilidad no deseada entre ensayos, que facilitó la posterior etapa de segmentación y el aprendizaje de patrones por parte de los modelos. El filtrado aplicado se mantuvo consistente para todos los sujetos y sesiones, además, se garantizó uniformidad en el tratamiento de los datos y se evitó posibles sesgos introducidos por diferencias en el preprocesamiento.

3.2.3. Segmentación de los datos

En la fase de segmentación, se realizó la segmentación temporal de las señales EEG en ventanas alineadas con los eventos de estímulo, con el fin de aislar los intervalos de interés asociados a cada tarea de imaginación motriz. A partir de los registros continuos, se extrajeron segmentos (epochs) definidos en un intervalo temporal específico posterior a la aparición del estímulo, esto aseguró que cada ventana contuviera la respuesta cerebral relevante para la tarea. Este procedimiento permitió sincronizar las señales en relación con el inicio del evento, lo que garantizó coherencia temporal entre las muestras.

Cada segmento fue definido con una duración fija, que permitió obtener representaciones homogéneas en términos de longitud temporal. Esta procedimiento

resultó muy útil para su posterior utilización en los modelos, que requieren entradas con dimensiones consistentes. De igual forma, se evitó la inclusión de intervalos previos al estímulo que no aportaran información discriminativa, solo enfocando el análisis en las regiones temporales donde se manifiestan patrones asociados a la imaginación motriz.

La segmentación generó múltiples muestras independientes a partir de cada registro continuo, se incrementó el número de ejemplos disponibles para el entrenamiento. Este incremento en la cantidad de datos permitió mejorar la capacidad de generalización de los modelos, al exponerlos a una mayor variabilidad intra e intersujeto.

Adicionalmente, se mantuvo la correspondencia entre cada segmento y su respectiva etiqueta de clase, lo que preservó la integridad del conjunto de datos supervisado. Este proceso permitió transformar las señales EEG continuas en un conjunto estructurado de muestras etiquetadas, adecuado para su utilización en tareas de clasificación.

En la tabla 3.1, se presentan los parámetros utilizados durante las etapas de preparación y preprocesamiento de las señales EEG.

TABLA 3.1. Parámetros de preparación y preprocesamiento de señales EEG

Etapa	Parámetro	Valor
Preparación	Dataset	Dreyer2023
	Acceso a datos	MOABB
	Número de sujetos	60
	Tipo de tarea	Imaginación motriz
	Clases	Mano izquierda / Mano derecha
	Número de canales EEG	27
	Sistema de electrodos	10-20
	Frecuencia de muestreo	512 Hz
	Número de runs por sesión	6
	Ensayos por run	40
Preprocesamiento	Tipo de señal	Señales crudas
	Filtro aplicado	Pasa banda
	Rango de filtrado	8–30 Hz
	Bandas analizadas	μ (8–13 Hz), β (13–30 Hz)
Segmentación	Tipo de ventana	Epochs alineados a estímulo
	Intervalo temporal	Posterior al estímulo
	Duración de ventana	Fija
Normalización	Tipo	Estandarización por muestra
Estructuración	Formato de entrada	(canales $\times$ tiempo)

3.3. Desarrollo de modelos

En esta sección se describe el desarrollo de los modelos implementados para la clasificación de señales EEG en tareas de imaginación motriz. Inicialmente, se presenta el modelo basado en redes convolucionales CNN. Posteriormente, se describe el modelo basado en redes neuronales recurrentes RNN, y finalmente,

se presenta el modelo híbrido CNN-RNN. Asimismo, se describen las configuraciones establecidas en las diferentes capas que conformaron los modelos.

3.3.1. Modelo basado en redes convolucionales

La estructura de entrada del modelo se definió para procesar las secuencias temporales provenientes de los 64 electrodos del conjunto de datos Dreyer2023A [10]. Esta representación preservó la estructura espacial de los electrodos y la evolución temporal de las señales, lo que permitió al modelo de capas convolucionales capturar patrones locales presentes en las señales EEG.

Las primeras capas convolucionales se configuraron para extraer patrones temporales de corta duración asociados a variaciones espectrales presentes en las bandas μ y β [2, 12]. Posteriormente, se aplicaron convoluciones espaciales orientadas a modelar relaciones entre diferentes canales EEG. Este enfoque permitió capturar información distribuida sobre distintas regiones en las señales EEG.

Después de las capas convolucionales, se incorporaron funciones de activación no lineales y capas de normalización. Estas capas estabilizaron la distribución interna de las representaciones generadas durante el entrenamiento y favorecieron la convergencia del modelo. Asimismo, se utilizaron operaciones de reducción dimensional, que disminuyeron la complejidad computacional y redujeron la redundancia presente en las características extraídas.

Con el propósito de reducir el sobreajuste, se incorporó la técnica de dropout [13] en diferentes etapas de la arquitectura. Este mecanismo realizó una desactivación aleatoria de neuronas durante el entrenamiento, que evitó una dependencia excesiva de patrones específicos presentes en el conjunto de datos. Su utilización resultó relevante debido a la variabilidad intra e intersujeto característica de las señales EEG.

En las etapas finales del modelo, se utilizó capas densamente conectadas encargadas de integrar las representaciones espaciales y temporales aprendidas previamente. Estas capas transformaron las características extraídas en probabilidades asociadas a cada clase de imaginación motriz. La salida del modelo se configuró para realizar una clasificación binaria correspondiente a tareas de imaginación motriz de mano izquierda y mano derecha presentes en el conjunto Dreyer2023A.

La arquitectura convolucional implementada permitió procesar señales EEG multicanal y aprender representaciones discriminativas directamente desde los datos preprocesados. Este enfoque evitó la necesidad de definir manualmente características espectrales o espaciales antes del entrenamiento, que favoreció un flujo de procesamiento más uniforme e integrado.

3.3.2. Modelo basado en redes neuronales recurrentes

La estructura de entrada del modelo se definió a partir de secuencias temporales organizadas por los canales de EEG y muestras en el tiempo. Esta representación preservó la evolución temporal de la actividad cerebral presente en cada ensayo. A diferencia de las arquitecturas convolucionales, el modelo recurrente priorizó el análisis de dependencias temporales entre diferentes instantes de la señal EEG.

La arquitectura recurrente se basó en capas LSTM que procesaron secuencialmente la información temporal presente en cada segmento de EEG. Se definió una

configuración de dos capas apiladas con sesenta y cuatro unidades ocultas cada una; esta estructura favoreció la mitigación de la pérdida de información a través de sus mecanismos de compuertas. Dichos elementos internos regularon el flujo de datos para retener las características relevantes provenientes de los estados anteriores. Como resultado, el modelo logró establecer una relación sólida entre las variaciones de amplitud de los sesenta y cuatro canales electroencefalográficos y la intención motriz evaluada.

De igual manera que en el modelo basado en redes convolucionales, se incorporaron funciones de activación no lineales, mecanismos de regularización y capas orientadas a estabilizar el proceso de entrenamiento. Estas configuraciones favorecieron la convergencia del modelo y contribuyeron a mejorar la estabilidad de las representaciones internas generadas durante el aprendizaje.

En las etapas finales del modelo, se utilizaron capas densamente conectadas encargadas de integrar las representaciones temporales aprendidas previamente por las capas LSTM. Estas capas transformaron las características extraídas en probabilidades asociadas a cada clase de imaginación motriz. La salida del modelo se configuró para realizar una clasificación binaria correspondiente a tareas de imaginación motriz de mano izquierda y mano derecha presentes en el conjunto Dreyer2023A.

La arquitectura basada en capas LSTM permitió procesar secuencias temporales de señales EEG multicanal y modelar dependencias temporales presentes en las tareas de imaginación motriz. Este enfoque permitió aprender representaciones asociadas a la dinámica temporal de la actividad cerebral directamente a partir de los datos preprocesados, lo que evitó la definición manual de características temporales antes del entrenamiento.

3.3.3. Modelo híbrido basado en CNN-LSTM

El tercer modelo implementado correspondió a una arquitectura híbrida basada en redes convolucionales y redes neuronales recurrentes LSTM. Este enfoque integró las capacidades de extracción espacial de las arquitecturas convolucionales con el modelado temporal proporcionado por las capas LSTM. Esta combinación de arquitecturas permitió procesar simultáneamente características espaciales y temporales en las señales EEG asociadas a tareas de imaginación motriz.

La estructura de entrada se definió a partir de segmentos EEG organizados en matrices bidimensionales compuestas por canales y muestras temporales. La primera etapa de la arquitectura correspondió a un bloque de redes convolucionales configurado para procesar los canales EEG presentes en el conjunto de datos Dreyer2023A. Estas capas realizaron la extracción de características espaciales locales presentes en las señales EEG e identificaron patrones asociados a variaciones entre diferentes canales y regiones relacionadas con tareas de imaginación motriz.

Posteriormente, las representaciones generadas por las capas convolucionales fueron procesadas mediante capas LSTM. Estas capas analizaron la evolución temporal de las características extraídas previamente, lo que permitió modelar dependencias temporales presentes a lo largo de la señal EEG. La integración entre capas convolucionales y recurrentes permitió capturar simultáneamente información espacial y temporal durante el proceso de aprendizaje.

De igual manera que en las arquitecturas previamente descritas, se incorporaron funciones de activación no lineales, mecanismos de regularización y capas dropout orientadas a mejorar la estabilidad del entrenamiento y reducir el sobreajuste. Estas configuraciones favorecieron la capacidad de generalización del modelo frente a señales EEG provenientes de distintos sujetos y ensayos.

En las etapas finales del modelo, se utilizaron capas densamente conectadas encargadas de integrar las representaciones espaciales y temporales aprendidas por la arquitectura híbrida. Estas capas transformaron las características extraídas en probabilidades asociadas a cada clase de imaginación motriz. La salida del modelo se configuró para realizar una clasificación binaria correspondiente a tareas de imaginación motriz de mano izquierda y mano derecha presentes en el conjunto Dreyer2023A.

La arquitectura híbrida implementada permitió combinar la capacidad de extracción espacial de las redes convolucionales con el modelado temporal de las capas LSTM. Este enfoque favoreció el aprendizaje conjunto de patrones espaciales y dinámicas temporales presentes en las señales EEG asociadas a tareas de imaginación motriz.

A continuación, se presentan las configuraciones principales utilizadas en las arquitecturas implementadas para la clasificación de señales EEG en tareas de imaginación motriz.

TABLA 3.2. Configuración de las arquitecturas implementadas

Componente	CNN	RNN-LSTM	CNN-LSTM
Entrada	Segmentos EEG multicanal	Secuencias temporales EEG	Segmentos EEG multicanal
Representación de entrada	(canales $\times$ tiempo)	(canales $\times$ tiempo)	(canales $\times$ tiempo)
Capas principales	Capas convolucionales	Capas LSTM	Capas convolucionales y LSTM
Extracción espacial	Sí	No	Sí
Modelado temporal	Limitado	Sí	Sí
Capas recurrentes	No aplica	2	1
Unidades ocultas	No aplica	64	64
Regularización	Dropout	Dropout	Dropout
Normalización	Sí	Sí	Sí
Capas densas finales	Sí	Sí	Sí
Salida	Clasificación binaria	Clasificación binaria	Clasificación binaria
Clases	Mano izquierda / derecha	Mano izquierda / derecha	Mano izquierda / derecha
Dataset	Dreyer2023A	Dreyer2023A	Dreyer2023A

3.4. Configuración del entrenamiento

En esta sección se describen las configuraciones utilizadas durante el proceso de entrenamiento de los modelos, así como la estrategia de búsqueda de hiperparámetros aplicada para optimizar el desempeño en la clasificación de señales EEG asociadas a tareas de imaginación motriz.

El proceso de entrenamiento se realizó utilizando los segmentos EEG obtenidos durante las etapas de preparación y preprocesamiento descritas previamente. Las muestras fueron organizadas en conjuntos de entrenamiento y validación, lo que permitió evaluar el comportamiento de las arquitecturas implementadas durante el aprendizaje.

Con el propósito de optimizar el desempeño de los modelos, se realizó una búsqueda de hiperparámetros orientada a identificar configuraciones adecuadas para cada arquitectura. Este procedimiento consideró parámetros relacionados con la capacidad de aprendizaje, estabilidad del entrenamiento y capacidad de generalización frente a señales EEG provenientes de distintos sujetos y ensayos.

En esta fase del desarrollo se implementó un proceso de búsqueda automatizada para definir la configuración estructural y de entrenamiento de los modelos propuestos. Debido a que la selección manual de hiperparámetros resulta intensiva a nivel computacional y susceptible al sesgo humano, se utilizó el entorno de optimización Optuna [14]; esta herramienta permitió explorar el espacio de soluciones de manera eficiente y sistemática.

El proceso de optimización requirió la definición de un espacio de búsqueda específico para cada una de las tres arquitecturas evaluadas. Las variables transversales a todos los modelos incluyeron la tasa de aprendizaje del optimizador, el tamaño del lote de datos y el dropout. Para el modelo CNN, el espacio de exploración abarcó adicionalmente la cantidad de filtros por bloque y las dimensiones de los núcleos convolucionales. En el caso de la arquitectura RNN, la herramienta iteró sobre el número óptimo de unidades ocultas dentro de las capas LSTM. Finalmente, para el enfoque híbrido, se asignó un rango de búsqueda que combinó los parámetros de extracción espacial y de modelado temporal; esto garantizó una sintonización conjunta y equilibrada de ambas etapas de procesamiento.

La automatización se estructuró en torno a una función objetivo, esta se encargó de guiar el proceso de búsqueda y para cada combinación de parámetros sugerida de dicha función instanció la red neuronal correspondiente, se ejecutó un ciclo de entrenamiento completo y evaluó el desempeño del sistema. En lugar de utilizar la exactitud global como único indicador, se seleccionó la métrica F1-score para cuantificar el rendimiento; este indicador calculó el balance entre la precisión y la exhaustividad de manera independiente para cada clase. Su uso resultó fundamental para obtener una evaluación rigurosa del comportamiento del modelo frente a las señales de EEG, pues penalizó de forma severa tanto los falsos positivos como los falsos negativos sin que una clase predominara sobre la otra.

El algoritmo del entorno ejecutó múltiples ensayos independientes para cada arquitectura. En cada iteración, el sistema registró el valor de la función objetivo y ajustó la selección de los hiperparámetros siguientes para maximizar el resultado. Tras concluir la cantidad de ensayos programados, la herramienta identificó la combinación exacta de valores que reportó el mayor desempeño en el subconjunto de validación. Posteriormente, estas configuraciones óptimas se aplicaron en la definición final de los tres modelos de clasificación, lo cual aseguró su máxima eficiencia y capacidad de generalización antes de la etapa de evaluación definitiva.

A continuación, se presentan los principales hiperparámetros considerados durante el entrenamiento de las arquitecturas implementadas.

TABLA 3.3. Hiperparámetros utilizados durante el entrenamiento

Hiperparámetro	Configuración evaluada
Número de capas convolucionales	1 a 3 capas
Número de filtros	16 a 128 filtros
Tamaño de kernel	3 y 5
Unidades ocultas LSTM	64 unidades
Dropout	0.1 a 0.5
Tamaño de capa densa	64 a 256 neuronas
Tasa de aprendizaje	Ajuste experimental
Batch size	Ajuste experimental
Número de épocas	Definido experimentalmente
Optimizador	Adam
Función de pérdida	Clasificación binaria
Métricas monitoreadas	Accuracy, Precision, Recall y F1-score

3.5. Protocolo de evaluación

En esta sección se describen las métricas y el procedimiento utilizado para evaluar el desempeño de las arquitecturas implementadas en la clasificación de señales EEG asociadas a tareas de imaginación motriz.

La evaluación de los modelos se realizó utilizando los conjuntos de validación definidos durante el proceso de entrenamiento. Este procedimiento permitió analizar el comportamiento de las arquitecturas CNN, LSTM y CNN-LSTM frente a señales EEG no observadas previamente, lo que facilitó la comparación de su capacidad de generalización sobre tareas de imaginación motriz.

Debido a la naturaleza de clasificación binaria del conjunto Dreyer2023A, la evaluación se orientó a medir la capacidad de los modelos para discriminar correctamente entre tareas de imaginación motriz de mano izquierda y mano derecha. Para ello, se emplearon métricas ampliamente utilizadas en problemas de clasificación aplicados a aprendizaje profundo y análisis de señales EEG [6, 12].

La principal métrica utilizada correspondió a la exactitud (accuracy), la que permitió medir la proporción de predicciones correctas realizadas por el modelo sobre el total de muestras evaluadas. Esta métrica proporcionó una medida general del desempeño alcanzado por las arquitecturas implementadas. Adicionalmente, se utilizaron métricas de precisión (precision), exhaustividad (recall) y puntuación F1 (F1-score). Estas métricas permitieron evaluar el comportamiento del modelo desde diferentes perspectivas relacionadas con la calidad de las predicciones realizadas.

La precisión permitió medir la proporción de tareas de imaginación motriz clasificadas correctamente respecto al total de predicciones positivas generadas por el modelo. Esta métrica resultó relevante para analizar la confiabilidad de las clasificaciones obtenidas a partir de patrones presentes en las señales EEG, especialmente en escenarios donde variaciones corticales similares pueden generar ambigüedad entre clases.

La exhaustividad permitió medir la capacidad del modelo para identificar correctamente muestras EEG pertenecientes a cada tarea de imaginación motriz. Esta

métrica resultó importante para evaluar la sensibilidad de las arquitecturas frente a patrones temporales y espaciales asociados a la actividad cortical registrada durante la imaginación motriz de mano izquierda y mano derecha.

Por otra parte, la puntuación F1 permitió integrar precisión y exhaustividad en una única métrica de desempeño. Esta medida facilitó la evaluación equilibrada del comportamiento de los modelos frente a la variabilidad inherente de las señales EEG, lo que proporcionó una medida más robusta del desempeño general de las arquitecturas implementadas [6, 12].

Durante la evaluación, se monitoreó el comportamiento de las métricas sobre los conjuntos de entrenamiento y validación, lo que permitió identificar posibles casos de sobreajuste y analizar la estabilidad de las arquitecturas implementadas. Asimismo, se evaluó la capacidad de generalización de los modelos frente a señales EEG provenientes de distintos sujetos y ensayos, aspecto relevante debido a la alta variabilidad intra e intersujeto presente en tareas de imaginación motriz.

TABLA 3.4. Métricas utilizadas para la evaluación de modelos EEG en tareas de imaginación motriz

Métrica	Descripción estadística	Relevancia en señales EEG
Exactitud	Proporción de predicciones correctas sobre el total de muestras EEG evaluadas.	Ofreció una visión global del desempeño alcanzado por las arquitecturas neuronales durante la clasificación de tareas de imaginación motriz.
Precisión	Relación entre verdaderos positivos y el total de predicciones positivas realizadas por el modelo.	Indicó la confiabilidad del modelo al identificar patrones EEG asociados a tareas de imaginación motriz de mano izquierda y mano derecha.
Exhaustividad	Relación entre verdaderos positivos y el total de muestras reales pertenecientes a una clase.	Permitió evaluar la capacidad del modelo para identificar correctamente señales EEG asociadas a la intención motriz del usuario.
Puntuación F1	Media armónica entre precisión y exhaustividad calculada sobre las clases evaluadas.	Constituyó una métrica robusta para comparar el desempeño de las arquitecturas CNN, LSTM y CNN-LSTM frente a la variabilidad presente en señales EEG.

3.6. Despliegue del modelo

En esta sección se describe el procedimiento de despliegue que se implementó para el modelo seleccionado, así como la infraestructura utilizada para realizar inferencia sobre señales EEG asociadas a tareas de imaginación motriz.

El despliegue se realizó con una arquitectura cloud basada en servicios de AWS, que esta orientada a desacoplar las etapas de procesamiento, inferencia y consumo del modelo entrenado. Este enfoque permitió separar el entorno de entrenamiento del entorno de inferencia, lo que facilitó la integración del sistema con servicios externos y componentes orientados al procesamiento de señales EEG.

El proceso inició con la serialización sistemática de los modelos. Esta operación permitió capturar y almacenar el estado exacto de los pesos sinápticos tras alcanzar el rendimiento óptimo en la fase de validación; para ello, se guardaron los diccionarios de estado de la arquitectura en almacenamiento persistente. A la par, la gestión integral del ciclo de vida del aprendizaje se organizó mediante la herramienta MLflow [15]; esta plataforma estructuró las ejecuciones en experimentos discretos y facilitó la trazabilidad exhaustiva de los hiperparámetros, las métricas de desempeño y los metadatos relevantes de cada ensayo.

Posteriormente, el modelo fue exportado utilizando el formato ONNX (del inglés, *Open Neural Network Exchange*), lo que permitió convertir la arquitectura entrenada a un formato portable e interoperable. Este enfoque facilitó la ejecución del modelo fuera del entorno original de entrenamiento y permitió su integración con diferentes plataformas de inferencia, servicios cloud y entornos de producción. La utilización de ONNX favoreció la portabilidad del sistema y redujo dependencias específicas del framework utilizado durante el entrenamiento.

El entorno de inferencia fue desplegado sobre servicios serverless de AWS, utilizando funciones Lambda para ejecutar el procesamiento del modelo de manera remota. Asimismo, se desarrolló una API REST utilizando FastAPI, encargada de gestionar las solicitudes de inferencia y la comunicación entre el cliente y el modelo desplegado. Este enfoque permitió escalar dinámicamente el sistema frente a múltiples solicitudes de inferencia y reducir el consumo de recursos cuando no existían peticiones activas. A continuación, en la tabla 3.5 se presentan los principales componentes considerados durante el despliegue y una estimación mensual asociada al coste de inferencia de señales EEG para un prototipo inicial.

TABLA 3.5. Estimación de costos de despliegue e inferencia del sistema EEG

Componente	Descripción	Consumo	Costo unitario (USD)	Costo mensual (USD)
API Gateway	Gestión de solicitudes REST.	10 000 solicitudes	3,50 por 1 000 000 solicitudes	0,04
AWS Lambda	Inferencia del modelo EEG.	100 000 GB-segundos	0,0000166 por GB-segundo	1,67
Amazon S3	Almacenamiento del modelo ONNX.	1 GB estándar	0,023 por GB mensual	0,02
CloudWatch	Monitoreo y registros del sistema.	1 GB procesado	0,50 por GB procesado	0,50
Transferencia de datos	Tráfico de salida.	1 GB de salida	0,09 por GB	0,09
Costo total	Operación mensual estimada.	-	-	2,32

A continuación, se presenta el flujo general de despliegue e inferencia 3.2 que se implementó para el procesamiento de señales EEG asociadas a tareas de imaginación motriz.




FIGURA 3.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Jonathan R. Wolpaw et al. «Brain-computer interfaces for communication and control». En: *Clinical Neurophysiology* 113.6 (2002), págs. 767-791.
- [2] Gert Pfurtscheller y Christa Neuper. «Motor imagery and direct brain-computer communication». En: *Proceedings of the IEEE* 89.7 (2001), págs. 1123-1134.
- [3] Alexander J. Casson et al. «Wearable electroencephalography». En: *IEEE Engineering in Medicine and Biology Magazine* 29.3 (2010), págs. 44-56.
- [4] Robin Tibor Schirrmeister et al. «Deep learning with convolutional neural networks for EEG decoding and visualization». En: *Human Brain Mapping* 38.11 (2017), págs. 5391-5420.
- [5] Vernon J. Lawhern et al. «EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 15.5 (2018).
- [6] Yannick Roy et al. «Deep learning-based electroencephalography analysis: a systematic review». En: *Journal of Neural Engineering* 16.5 (2019).
- [7] Pouya Bashivan et al. «Learning representations from EEG with deep recurrent-convolutional neural networks». En: *arXiv preprint arXiv:1511.06448* (2015).
- [8] Alexander Craik, Yongtian He y Jose L. Contreras-Vidal. «Deep learning for electroencephalogram (EEG) classification tasks: a review». En: *Journal of Neural Engineering* 16.3 (2019).
- [9] Fabien Lotte et al. «A review of classification algorithms for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 4.2 (2007).
- [10] Alaric M. Dreyer et al. «A large electroencephalography dataset for the study of motor imagery». En: *Scientific Data* 10.1 (2023), pág. 583. DOI: [10.1038/s41597-023-02445-z](https://doi.org/10.1038/s41597-023-02445-z).
- [11] Jaime Riascos, Marta Molinas y Fabien Lotte. «Machine Learning Methods for BCI: challenges, pitfalls and promises». En: *ESANN 2024-European symposium on artificial neural networks, computational intelligence and machine learning*. 2024.
- [12] Ding Zhang et al. «EEG-based brain-computer interfaces using deep learning: A review». En: *Biomedical Signal Processing and Control* 63 (2021), pág. 102172.
- [13] Nitish Srivastava et al. «Dropout: A Simple Way to Prevent Neural Networks from Overfitting». En: *Journal of Machine Learning Research* 15.56 (2014), págs. 1929-1958.
- [14] Takuya Akiba et al. «Optuna: A Next-generation Hyperparameter Optimization Framework». En: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. ACM, 2019, págs. 2623-2631. DOI: [10.1145/3292500.3330701](https://doi.org/10.1145/3292500.3330701).
- [15] Matei Zaharia et al. «Accelerating the Machine Learning Lifecycle with ML-flow». En: *IEEE Data Engineering Bulletin* 41.4 (2018), págs. 39-45.