

Interfaces cerebro-cloud para la predicción de actividades de imaginación motriz

Ing. Freddy Julian Riascos Salas

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Ing. Jaime Andrés Riascos Salas (Potsdam Embodied Cognition Group)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Pasto, junio de 2026

Resumen

En la presente memoria se describe el desarrollo de un sistema de inteligencia artificial enfocado en la predicción de tareas de imaginación motriz usando señales de electroencefalografía. Este trabajo busca dejar una base técnica para el desarrollo de sistemas de interacción cerebro-computador en imaginación motriz para predecir la intención de movimiento en usuarios.

Para su implementación fueron necesarios los conocimientos adquiridos en la especialización incluidos procesamiento y análisis de datos, aprendizaje automático, redes neuronales y operaciones.

Agradecimientos

A mi familia, por ser el motor que impulsa mis sueños.

Por estar presente en cada paso, por creer en mí incluso cuando el camino parecía incierto y por recordarme siempre que detrás de cada meta existe una razón para seguir adelante.

Cada logro lleva un poco de ustedes: su amor, su paciencia, sus palabras de ánimo y todos esos pequeños sacrificios que muchas veces pasan desapercibidos, pero que hacen posible llegar más lejos.

Este proyecto, este sueño y todo lo que está por venir también les pertenece.

Gracias por ser mi inspiración, mi fuerza y mi hogar. .

Índice general

Resumen	I
1. Introducción general	1
1.1. Interfaces cerebro-computador	1
1.1.1. Arquitectura funcional de un sistema BCI	1
1.1.2. Dispositivos de adquisición de señales EEG	2
1.2. Estado del arte	2
1.3. Motivación	3
1.4. Objetivos y alcance	4
1.4.1. Objetivo general	4
1.4.2. Objetivos específicos	4
1.4.3. Alcance	4
2. Introducción específica	5
2.1. Adquisición de datos	5
2.1.1. Configuración técnica y estructura del conjunto de datos	5
2.2. Métodos tradicionales en EEG y extracción automática de características	7
2.3. Arquitecturas de redes neuronales para EEG en tareas de imaginación motriz	8
3. Diseño e implementación	11
3.1. Arquitectura del sistema	11
3.1.1. Componentes del flujo de procesamiento	12
3.2. Preparación y preprocesamiento de los datos	13
3.2.1. Preparación de los datos	13
3.2.2. Preprocesamiento de los datos	14
3.2.3. Segmentación de los datos	14
3.2.4. Estandarización y control de calidad	15
3.3. Desarrollo de modelos	17
3.3.1. Modelo basado en redes convolucionales	17
3.3.2. Modelo basado en redes neuronales recurrentes	18
3.3.3. Modelo híbrido basado en CNN-LSTM	19
3.4. Configuración del entrenamiento	22
3.4.1. Ciclo de entrenamiento	22
3.5. Protocolo de evaluación	24
3.6. Despliegue del modelo	26
3.6.1. Infraestructura de inferencia	27
4. Ensayos y resultados	31
4.1. Ensayos de modelos	31
5. Conclusiones	33

5.1. Conclusiones generales	33
5.2. Próximos pasos	33
Bibliografía	35

Índice de figuras

2.1. Distribución de electrodos según el sistema 10-20 utilizado en la adquisición de señales EEG.	6
2.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.	8
3.1. Diagrama de la arquitectura general del sistema.	13
3.2. Arquitectura general del modelo de clasificación de señales EEG implementado.	17
3.3. Flujo de despliegue e inferencia del modelo de clasificación de señales EEG.	30

Índice de tablas

1.1. Comparativa de enfoques	3
2.1. dataset dreyer	6
2.2. Comparación entre modelos	7
2.3. Comparación entre arquitecturas	9
3.1. Parámetros Dataset	16
3.2. Configuración de las arquitecturas implementadas.	21
3.3. Hiperparámetros utilizados durante el entrenamiento.	24
3.4. Métricas utilizadas para la evaluación de modelos EEG en tareas de imaginación motriz.	26
3.5. Estimación de costos de despliegue e inferencia del sistema EEG.	29
4.1. Configuración de los experimentos realizados.	32

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presentan los fundamentos de las tecnologías de interfaz cerebro-computador y se describe el estado actual de la investigación en el área. Asimismo, se exponen la motivación, los objetivos y el alcance definidos para el desarrollo del trabajo.

1.1. Interfaces cerebro-computador

Las interfaces cerebro-computador o BCI (del inglés, *Brain-Computer Interface*) se definen como sistemas que establecen una vía de comunicación directa entre el cerebro humano y un dispositivo externo [1]. Estos sistemas permiten la traducción de patrones de actividad cerebral en comandos de control sin la intervención de las vías periféricas neuromusculares tradicionales.

El funcionamiento de una BCI se fundamentó en la adquisición de señales bioeléctricas, su procesamiento digital y la posterior ejecución de acciones en un entorno computacional o físico. En el desarrollo de este trabajo, se consideraron las señales electroencefalográficas o EEG (*electroencephalogram*) debido a su naturaleza no invasiva y su capacidad para registrar la intención motriz del usuario en tiempo real. La integración de estos dispositivos con servicios en la nube facilita el procesamiento de grandes volúmenes de datos, lo que permite optimizar la capacidad de respuesta de los sistemas ante tareas de imaginación motriz.

1.1.1. Arquitectura funcional de un sistema BCI

El modelo operativo de una BCI inicia con una cadena de procesamiento compuesta por etapas secuenciales. En la fase inicial, se realiza la adquisición de señales mediante sensores electroencefalográficos colocados sobre el cuero cabelludo. Luego, los datos crudos se someten a procesos de preprocesamiento para la eliminación de artefactos, tales como parpadeos o movimientos musculares, mediante el uso de filtros digitales. Posteriormente, se realiza la extracción de características que permite identificar los componentes relevantes de la señal asociados a la intención del usuario. Finalmente, se implementan algoritmos de clasificación para traducir dichas características en comandos de control.

En este contexto, la imaginación motriz se define como el proceso cognitivo en el que un individuo simula mentalmente una acción motora sin ejecutar un movimiento físico real [2]. Este fenómeno produce cambios detectables en los ritmos sensorimotrices de la corteza cerebral, específicamente en las bandas de frecuencia mu (8–13 Hz) y beta (13–30 Hz), que constituyen la base fisiológica para la decodificación de la intención de movimiento en sistemas BCI.

1.1.2. Dispositivos de adquisición de señales EEG

La captura de la actividad eléctrica cerebral se realiza habitualmente mediante sistemas de EEG. Estos se clasifican según su movilidad y el tipo de sensores empleados. En el ámbito de la investigación, se destacan dispositivos de grado médico y equipos portátiles diseñados para aplicaciones fuera del entorno clínico, estos han sido ampliamente abordados en la literatura científica[3]. Aunque en este trabajo se utilizó un conjunto de datos o dataset previamente registrado, la comprensión de estos dispositivos resultó pertinente para el análisis de la calidad de la señal.

1.2. Estado del arte

La presente revisión del estado del arte tiene como objetivo identificar las metodologías dominantes en la clasificación de tareas de imaginación motriz mediante EEG. En los últimos años, el estudio de las BCI ha cobrado relevancia debido a la convergencia entre la neurociencia computacional y el aprendizaje profundo, lo que permite aprender directamente de las señales crudas, sin depender de métodos tradicionales de extracción de características como el patrón espacial común o CSP (*Common Spatial Pattern*) [4].

Las redes neuronales convolucionales o CNN (*Convolutional Neural Network*) constituyen una de las aproximaciones más utilizadas. Estas redes capturan patrones espaciales en las señales EEG y han demostrado un buen desempeño en la clasificación de tareas de imaginación motriz. Modelos como EEGNet introducen arquitecturas compactas que logran buenos resultados incluso con pocos datos de entrenamiento [5].

Por otra parte, las redes recurrentes, especialmente las de memoria a corto y largo plazo o LSTM (*Long Short-Term Memory*), permiten modelar la dinámica temporal de las señales EEG. Estas arquitecturas capturan dependencias en el tiempo que resultan clave para identificar patrones asociados a la imaginación de movimiento. Estudios recientes reportan que modelos basados en LSTM alcanzan desempeños superiores frente a métodos tradicionales [6].

Asimismo, las arquitecturas híbridas que combinan CNN y LSTM han ganado relevancia. Estas combinaciones permiten integrar información espacial y temporal en un mismo modelo. Investigaciones muestran que este enfoque mejora la capacidad de generalización y aumenta la precisión en comparación con modelos individuales [6, 7].

En los trabajos más recientes, se han propuesto variantes más eficientes como redes convolucionales ligeras y modelos que operan en el dominio frecuencial. Estas propuestas buscan reducir la complejidad del modelo y mejorar el rendimiento con conjuntos de datos limitados, lo que representa un desafío común en aplicaciones de interfaces cerebro-computador [8].

La literatura técnica muestra un interés en el desplazamiento desde los métodos basados en la extracción manual de características, como los CSP, hacia sistemas de aprendizaje profundo. Mientras que los algoritmos tradicionales destacan por su baja carga computacional, las investigaciones recientes exponen que las arquitecturas híbridas logran una mayor robustez ante la variabilidad entre sujetos.

Sin embargo, aún persisten retos relacionados con la variabilidad entre usuarios, la necesidad de grandes volúmenes de datos y la robustez en entornos reales [6].

En la tabla 1.1 se presenta la comparativa técnica de las arquitecturas y enfoques identificados en la revisión bibliográfica.

TABLA 1.1. Comparativa de enfoques tecnológicos para la clasificación de imaginación motriz.

Enfoque	Técnicas	Ventajas	Limitaciones
Estadístico	CSP + SVM	Alta interpretabilidad y eficiencia en sistemas embebidos.	Sensible a artefactos y requiere calibración manual.
Redes Convolucionales	CNN (EEGNet)	Reducción de parámetros y extracción automática de rasgos.	Necesidad de grandes volúmenes de datos etiquetados.
Arquitectura Híbrida	CNN + LSTM	Modelado de dependencias temporales y espaciales.	Complejidad computacional elevada y riesgo de sobreajuste.

1.3. Motivación

El desarrollo de este trabajo se justificó en la necesidad de mejorar la precisión en la predicción de la intención de movimiento de un usuario a partir de señales EEG asociadas a tareas de imaginación motriz. A pesar de los avances en el procesamiento de señales biológicas, los métodos tradicionales presentan dificultades para adaptarse a la variabilidad de los ritmos sensorimotrices entre diferentes individuos, lo que limita su aplicación en entornos reales fuera del laboratorio y representa un desafío significativo para la generalización en sistemas EEG [1, 9].

La implementación de modelos de inteligencia artificial avanzados permitió abordar la naturaleza no lineal y compleja de las señales de imaginación motriz, que presentan una alta variabilidad entre sujetos. Durante el análisis preliminar, se identificó que el procesamiento local en dispositivos embebidos restringía el uso de arquitecturas de aprendizaje profundo debido a las limitaciones de memoria y capacidad de cómputo de los sistemas portátiles. Por lo tanto, la integración de una infraestructura en la nube se presentó como una solución técnica viable para ejecutar modelos de alta complejidad sin comprometer la portabilidad ni la autonomía del sistema de adquisición.

Asimismo, la motivación de este trabajo residió en la creación de una arquitectura escalable que facilitara el entrenamiento continuo de los modelos. Al centralizar el procesamiento, se permitió la acumulación de datos para el refinamiento de los algoritmos, que busca una reducción significativa en el tiempo de calibración

requerido para cada usuario. Esta aproximación tecnológica no solo optimizó el rendimiento predictivo, sino que también sentó las bases para interfaces cerebro-computador más robustas y eficientes en la práctica clínica y asistencial.

1.4. Objetivos y alcance

El desarrollo de este trabajo se orientó a la creación de una infraestructura tecnológica capaz de procesar y clasificar señales EEG en un entorno distribuido. A continuación, se presentan el objetivo general, los objetivos específicos y el alcance del trabajo.

1.4.1. Objetivo general

Establecer una base técnica que permitiera analizar patrones neuronales asociados a tareas de imaginación motriz, que integra modelos de inteligencia artificial y servicios en la nube para servir como referencia en futuros desarrollos de interfaces cerebro-computador.

1.4.2. Objetivos específicos

Para cumplir con el objetivo general, se plantearon los siguientes objetivos específicos:

- Implementar una arquitectura de red neuronal capaz de identificar con precisión las intenciones de movimiento a partir de señales EEG.
- Diseñar un flujo de datos que integrara la adquisición de señales con el procesamiento remoto en una plataforma en la nube.
- Evaluar el desempeño del sistema mediante métricas de precisión y tiempo de respuesta en la clasificación de actividades de imaginación motriz.
- Documentar los procedimientos de preprocesamiento y entrenamiento para facilitar la replicabilidad del modelo en investigaciones posteriores.

1.4.3. Alcance

El alcance de este trabajo comprendió desde la selección y limpieza del conjunto de datos hasta el despliegue del modelo de inferencia en servidores remotos. Se limitó el estudio al análisis de tareas motoras binarias como el movimiento imaginado de la mano izquierda y la derecha. Se utilizan datasets de acceso público para garantizar la validación estadística de los resultados.

El sistema se diseñó para operar de forma asíncrona, que prioriza la precisión del clasificador sobre la respuesta inmediata de baja latencia. Se establece así un marco de trabajo robusto para la investigación de algoritmos complejos. No se incluyó en esta etapa el desarrollo de hardware de adquisición propio ni la implementación de biorretroalimentación en tiempo real para el usuario final.

Capítulo 2

Introducción específica

En este capítulo se presentan los procedimientos técnicos para la obtención de señales EEG y los métodos de extracción de características aplicados en este trabajo. Asimismo, se describen las arquitecturas de redes neuronales orientadas a la clasificación de tareas de imaginación motriz.

2.1. Adquisición de datos

El conjunto de datos seleccionado para este trabajo provino de los registros originales publicados por los autores del estudio Dreyer2023A [10], que presenta una base de datos de señales EEG orientada al análisis de la intención motora en sujetos sanos.

Es importante destacar que la adquisición de las señales EEG y el diseño del protocolo experimental fueron realizados por los autores del estudio original. En este trabajo no se llevó a cabo la recolección de datos, sino que se utilizó este conjunto de datos público como base para el desarrollo de los procesos de análisis, modelado y clasificación.

En el estudio original, la recolección de la actividad cerebral se realiza mediante un sistema de alta resolución que permite capturar las variaciones de potencial eléctrico en la corteza cerebral durante la ejecución de tareas mentales específicas, enfocadas en la discriminación de movimientos imaginados.

El protocolo experimental se fundamenta en un paradigma en el que los participantes realizan tareas de intención de movimiento de la mano izquierda y la mano derecha sin ejecución física. Cada ensayo sigue una secuencia temporal estricta que inicia con una fase de advertencia, seguida de una señal visual que indica la dirección del movimiento imaginado. Los sujetos mantienen la actividad mental durante un intervalo de cuatro segundos, lo que permite el registro de los ritmos sensorimotrices asociados a la planificación motora. Las condiciones del experimento se mantienen controladas en una habitación con aislamiento acústico para garantizar la repetibilidad de las mediciones.

2.1.1. Configuración técnica y estructura del conjunto de datos

En el estudio original, la captura de las señales la realizan mediante una distribución de 64 electrodos activos dispuestos según el sistema internacional 10-20, como puede observarse en la figura 2.1; estos se ubican sobre las áreas motoras y somatosensoriales. Esta disposición facilita la detección de los fenómenos de desincronización relacionada con eventos, que resultan fundamentales para la

2.2. Métodos tradicionales en EEG y extracción automática de características

Tradicionalmente, la decodificación de la imaginación motriz se basa en algoritmos de aprendizaje automático combinados con una etapa de ingeniería de rasgos manual. El enfoque más común utiliza CSP, técnica que descompone las señales para maximizar la varianza entre clases y facilitar la separación de estados mentales [11]. A partir de estos patrones, se emplean clasificadores como LDA (*Linear Discriminant Analysis*) y SVM (*Support Vector Machines*). Aunque efectivos en entornos controlados, estos métodos son sensibles a la colocación de electrodos y requieren ajuste experto de las bandas de frecuencia por sujeto.

Frente a estas limitaciones, el avance hacia el aprendizaje profundo o Deep Learning ha permitido el desarrollo de modelos capaces de realizar la extracción automática de características. A diferencia de los esquemas clásicos, estas arquitecturas aprenden representaciones jerárquicas directamente a partir de los datos crudos, y se reduce la necesidad de una ingeniería de rasgos manual.

Sin embargo, diversos estudios han señalado que la calidad de la adquisición de las señales EEG continúa siendo un factor determinante en el desempeño de estos modelos. Una configuración deficiente en la toma de muestras o una inadecuada colocación de los sensores puede introducir artefactos que las redes neuronales interpretan erróneamente como patrones fisiológicos, lo que afecta la robustez de la predicción. Por lo tanto, aunque los modelos de aprendizaje profundo contengan la capacidad de identificar características complejas, su desempeño depende en gran medida de la calidad y fidelidad de las señales de entrada.

En la tabla 2.2 se presenta una comparación entre los métodos tradicionales de procesamiento de EEG y las técnicas de aprendizaje profundo. Estas destacan sus características, ventajas y limitaciones en el contexto del análisis de señales EEG para la clasificación de tareas de imaginación motriz.

TABLA 2.2. Comparación entre métodos tradicionales y modelos de aprendizaje profundo para el análisis de EEG.

Característica	Métodos tradicionales (CSP, SVM, LDA)	Aprendizaje profundo (CNN, EEGNet)
Extracción de rasgos	Manual y basada en conocimiento experto.	Automática a partir de los datos de entrada.
Sensibilidad al ruido	Muy alta, requiere filtros manuales estrictos.	Moderada, depende de la calidad del dato.
Manejo de datos	Requiere segmentación y filtrado previo.	Procesamiento con preprocesamiento mínimo.
Rendimiento	Limitado ante señales no estacionarias.	Mayor robustez y escalabilidad.
Dependencia	Alta dependencia de calibración por sujeto.	Posibilidad de aprendizaje transferido.

2.3. Arquitecturas de redes neuronales para EEG en tareas de imaginación motriz

Las CNN se consolidan como una de las herramientas más eficaces para la extracción de características. Mediante el uso de filtros de convolución, estas redes permiten identificar patrones de activación en regiones específicas de la corteza motora, que simula de manera automática el comportamiento de los filtros espaciales tradicionales. Por ello, el uso de las CNN facilita la detección de cambios en la amplitud de los ritmos sensorimotrices asociados a la intención de movimiento de las extremidades.

Por otro lado, para el análisis de la dinámica temporal de las señales EEG, las redes neuronales recurrentes o RNN (*Recurrent Neural Networks*), específicamente las unidades de memoria de largo corto plazo o LSTM y las unidades recurrentes calificadas o GRU (*Gated Recurrent Units*) permiten modelar la evolución de la señal a lo largo del tiempo; estas utilizan mecanismos de puertas para retener información relevante y descartar el ruido transitorio. Mientras que las LSTM emplean una estructura compleja para gestionar la memoria a largo plazo, las GRU ofrecen una alternativa más eficiente en términos computacionales, que mantiene un rendimiento competitivo en la clasificación de series temporales de EEG.

Por último, los enfoques híbridos han sido ampliamente utilizados para integrar las ventajas de distintos modelos en el análisis de señales EEG. En particular, las arquitecturas de tipo CNN-LSTM combinan la capacidad de las redes convolucionales para extraer características espaciales con la habilidad de las redes recurrentes para modelar dependencias temporales [12].

El enfoque híbrido y las arquitecturas de redes neuronales para el análisis de señales EEG se muestran en la figura 2.2, en la que se ilustra la estructura de cada modelo y su aplicación en la clasificación de tareas de imaginación motriz.




FIGURA 2.2. Estructura general de los modelos y su aplicación en la clasificación de tareas de imaginación motriz.

En este tipo de arquitecturas, las capas convolucionales permiten identificar patrones relevantes en la distribución espacial de los electrodos, mientras que las

capas recurrentes procesan la evolución temporal de dichas características. Esta combinación resulta adecuada para el manejo de la alta dimensionalidad de las señales EEG, que facilita la construcción de representaciones robustas previas a la etapa de clasificación.

En la tabla 2.3 se presenta una comparación técnica entre las arquitecturas de redes neuronales aplicadas al análisis de señales EEG, y se destacan las características, ventajas y limitaciones en el contexto de la clasificación de tareas de imaginación motriz. Esta comparación proporciona una visión integral de cómo cada enfoque contribuye al procesamiento de las señales EEG y a la mejora del rendimiento en la decodificación de la intención motora.

TABLA 2.3. Comparación entre arquitecturas CNN, LSTM y CNN-LSTM aplicadas al análisis de señales EEG.

Característica	CNN	LSTM / GRU	CNN-LSTM
Tipo de procesamiento	Espacial (filtros convolucionales)	Temporal (modelado secuencial)	Espacial + temporal combinado
Extracción de características	Automática en dominios espaciales locales	Basada en dependencias temporales	Extracción jerárquica espacio-temporal
Manejo de dependencias temporales	Limitado	Alto (memoria de corto y largo plazo)	Alto (integrado con características espaciales)
Complejidad computacional	Moderada	Alta	Alta
Robustez frente a ruido	Moderada	Moderada	Alta (por integración de representaciones)
Ventaja principal	Detección de patrones espaciales en electrodos	Modelado de dinámica temporal de la señal	Captura conjunta de patrones espaciales y temporales
Limitación principal	No modela secuencias largas	Alto costo y entrenamiento más complejo	Mayor complejidad y necesidad de ajuste fino
Aplicación en EEG	Identificación de activación cortical localizada	Análisis de evolución temporal de ritmos cerebrales	Clasificación integral de tareas de imaginación motriz

Capítulo 3

Diseño e implementación

En este capítulo se describen las etapas de diseño y el ajuste del sistema orientado a la clasificación de tareas de imaginación motriz. En las siguientes secciones se detallan la arquitectura del sistema, el tratamiento de los datos de origen, el desarrollo y entrenamiento de los modelos de aprendizaje profundo, así como el protocolo de evaluación y el despliegue final en la infraestructura de la nube.

3.1. Arquitectura del sistema

En esta sección se describe la arquitectura general del sistema que se utilizó para la predicción de tareas de imaginación motriz a partir de EEG.

El sistema se estructuró como un flujo secuencial compuesto por etapas de preparación de datos, preprocesamiento, extracción de características, inferencia mediante modelos de aprendizaje profundo y despliegue en infraestructura cloud. Este enfoque permitió integrar el procesamiento de señales EEG con servicios distribuidos, lo que facilitó la escalabilidad y la eficiencia en la ejecución de los modelos. La decisión de separar cada etapa en módulos independientes respondió a la necesidad de poder modificar o sustituir un componente del flujo sin afectar el comportamiento del resto, lo que simplificó el mantenimiento del sistema y favoreció su evolución incremental a lo largo del desarrollo del trabajo.

La fuente de datos correspondió al conjunto de datos Dreyer2023A [10]. Este contiene registros de señales EEG asociados a tareas de imaginación motriz. Dicho conjunto fue utilizado como base para el entrenamiento y evaluación de los modelos, sin realizar procesos de adquisición directa de señales.

Luego, se implementó una etapa de preprocesamiento orientada a mejorar la relación entre la señal y el ruido. En esta fase se aplicaron técnicas de filtrado y segmentación, con el fin de aislar ventanas relevantes para el análisis. Este procedimiento permitió reducir la variabilidad inherente a las señales EEG y facilitar el aprendizaje de patrones discriminativos.

La extracción de características se abordó mediante arquitecturas de redes neuronales, que permitieron modelar dependencias espaciales y temporales presentes en las señales. Se consideraron enfoques híbridos capaces de capturar correlaciones entre canales y dinámicas temporales, lo que resulta fundamental en tareas de imaginación motriz [12].

El módulo de inferencia se diseñó para recibir las representaciones procesadas y generar una predicción de la tarea imaginada. Este módulo se integró con un servicio web, que permitió exponer la funcionalidad del modelo por medio de una

API RESTful. De esta manera, se facilita la interacción con aplicaciones externas y la posibilidad de realizar predicciones en tiempo real.

Con el propósito de detallar la responsabilidad de cada componente, en los siguientes apartados se describen los módulos que conformaron la arquitectura del sistema y la función que cada uno desempeñó dentro del flujo global de procesamiento.

3.1.1. Componentes del flujo de procesamiento

El primer componente correspondió a la fuente de datos, encargada de suministrar las señales EEG al sistema. Este módulo se limitó a la lectura de los registros del conjunto Dreyer2023A, organizados por sujetos, sesiones y ensayos, y no requirió de ningún mecanismo de adquisición física. Su función consistió en normalizar el acceso a los datos mediante la interfaz de MOABB, de modo que las etapas posteriores operaran siempre sobre una representación estandarizada de las señales.

El segundo componente se encargó del preprocesamiento de las señales crudas. Este módulo aplicó las operaciones de filtrado y segmentación descritas en la sección siguiente, cuya finalidad fue eliminar componentes no deseados de la señal y aislar los intervalos temporales relevantes para la tarea de imaginación motriz. La salida de este componente consistió en un conjunto de muestras etiquetadas listas para ser consumidas por el modelo.

El tercer componente correspondió al módulo de aprendizaje, responsable de transformar las muestras preprocesadas en representaciones de alto nivel mediante las arquitecturas de redes neuronales evaluadas en el trabajo. Este módulo se subdividió en las etapas de extracción espacial, implementada con capas convolucionales, y de modelado temporal, implementada con capas recurrentes. Ambas etapas operaron de manera conjunta en el modelo híbrido para capturar las correlaciones entre canales y su evolución en el tiempo.

El cuarto componente agrupó el entorno de entrenamiento y evaluación, donde se realizaron las tareas de optimización de los hiperparámetros, el ajuste de los parámetros del modelo y la cuantificación de su desempeño. Este componente operó de forma desacoplada del entorno de inferencia, lo que permitió que el entrenamiento intensivo se ejecutara sobre recursos dedicados sin interferir con el servicio de predicción desplegado posteriormente.

El quinto y último componente correspondió al entorno de despliegue, implementado sobre servicios cloud de AWS. Este módulo expuso el modelo seleccionado por medio de una API REST, gestionó el preprocesamiento en el momento de la inferencia y respondió a las solicitudes de predicción provenientes de clientes externos. La separación entre el entorno de entrenamiento y el de despliegue constituyó un aspecto central del diseño, dado que permitió operar el modelo con recursos mínimos y escalar el servicio de manera independiente de la experimentación.

A continuación, se presenta la arquitectura general del sistema propuesto, en la que se ilustran las etapas principales del flujo de procesamiento y su integración dentro del entorno cloud.¹

¹El diagrama de bloques de la arquitectura general del sistema se muestra en la figura 3.1.

Esta arquitectura facilitó la implementación de una interfaz cerebro-computador cloud, en la que las señales fueron procesadas de manera remota para la generación de resultados. La elección de este paradigma se fundamentó en la posibilidad de centralizar el modelo y los datos, esto permitió que múltiples clientes accedieran al servicio de predicción sin necesidad de replicar la infraestructura en cada punto de uso. Asimismo, el enfoque cloud permitió aprovechar mecanismos de escalado automático para ajustar dinámicamente los recursos de inferencia según la demanda de solicitudes; en consecuencia, se estableció un flujo continuo desde la preparación de los datos hasta la obtención de predicciones que garantizó la modularidad, escalabilidad y capacidad de integración del sistema con aplicaciones externas.




FIGURA 3.1. Diagrama de la arquitectura general del sistema.

3.2. Preparación y preprocesamiento de los datos

En esta sección se describen los métodos aplicados a las señales EEG antes del entrenamiento de los modelos, estos incluyen las etapas de preparación, preprocesamiento, filtrado, segmentación, transformación y estandarización de los datos. La finalidad de esta cadena de procedimientos fue convertir las señales crudas, organizadas originalmente en registros continuos, en un conjunto de muestras homogéneas aptas para ser consumidas por las arquitecturas neuronales. Cada operación aplicada respondió a un criterio específico orientado a preservar la información relevante para la tarea y a reducir la influencia de las perturbaciones propias de la señal EEG.

3.2.1. Preparación de los datos

En la etapa de preparación, se realizó la carga de los registros EEG considerando su organización estructurada por sujetos, sesiones y ensayos, conforme a la definición del conjunto de datos Dreyer2023A descrito en [10]. Este conjunto incluye múltiples participantes sometidos a experimentos de imaginación motriz de mano izquierda y derecha, con un número significativo de ensayos por sesión, lo que permitió disponer de un volumen amplio de datos para el entrenamiento de los modelos. Por medio de la interfaz de MOABB (*Mother Of All BCI Benchmarks*), se accedió a los datos en un formato estandarizado basado en eventos, lo que facilitó la manipulación de las señales y su integración en el flujo de procesamiento.

El conjunto de datos agrupó un total de sesenta sujetos, cada uno de los cuales participó en seis ejecuciones por sesión con cuarenta ensayos por ejecución,

lo que arrojó un volumen de doscientos cuarenta ensayos por sujeto. Las señales fueron registradas con veintisiete canales EEG distribuidos según el sistema internacional 10-20 y una frecuencia de muestreo de quinientos doce hercios. Estas características determinaron la dimensionalidad de las muestras procesadas y condicionaron la configuración de las arquitecturas descritas en la sección siguiente.

Después, se identificaron los eventos asociados a cada tarea de imaginación motriz, que correspondían a etiquetas discretas como mano izquierda y mano derecha dentro del paradigma de clasificación binaria. Estos eventos permitieron segmentar las señales continuas en ensayos individuales alineados temporalmente con los estímulos experimentales. Cada ensayo representó una instancia etiquetada del conjunto de datos, lo que permitió estructurar la información en un esquema supervisado ideal para el entrenamiento de los modelos.

Por otra parte, se consideró la consistencia en la organización de los canales EEG y la sincronización temporal de las señales, lo que garantizó que cada muestra mantuviera la correspondencia entre dimensiones espaciales y temporales. Este proceso permitió transformar los datos originales en una representación homogénea, lo que facilitó su posterior procesamiento y aseguró la compatibilidad en términos de entradas estructuradas y uniformes con los modelos.

3.2.2. Preprocesamiento de los datos

En la fase de preprocesamiento, se aplicó un filtrado de las señales EEG con el objetivo de mejorar la relación señal y ruido para resaltar los componentes relevantes para la tarea de clasificación. Para eso, se empleó un filtro pasa banda en el rango de 8 a 30 Hz, se considera que este intervalo abarca las bandas μ (aproximadamente 8–13 Hz) y β (13–30 Hz), que están estrechamente relacionadas con la actividad cortical asociada a la imaginación motriz [2, 12]. Estas bandas presentan patrones característicos de desincronización y sincronización relacionados con la ejecución o imaginación de movimientos, lo que las convierte en una fuente relevante de información discriminativa.

El filtrado permitió atenuar componentes de muy baja frecuencia, asociadas a derivas de la señal y artefactos fisiológicos como la actividad electrodermal, así como reducir el ruido de alta frecuencia proveniente de interferencias externas o actividad muscular no deseada. De esta manera, se preservó la información espectral de interés mientras se eliminaban componentes irrelevantes para la tarea.

De igual forma, este proceso contribuyó a estabilizar la señal y a reducir la variabilidad no deseada entre ensayos, que facilitó la posterior etapa de segmentación y el aprendizaje de patrones por parte de los modelos. El filtrado aplicado se mantuvo consistente para todos los sujetos y sesiones, además, se garantizó uniformidad en el tratamiento de los datos y se evitó posibles sesgos introducidos por diferencias en el preprocesamiento.

3.2.3. Segmentación de los datos

En la fase de segmentación, se realizó la segmentación temporal de las señales EEG en ventanas alineadas con los eventos de estímulo, con el fin de aislar los intervalos de interés asociados a cada tarea de imaginación motriz. A partir de

los registros continuos, se extrajeron segmentos (epochs) definidos en un intervalo temporal específico posterior a la aparición del estímulo, esto aseguró que cada ventana contuviera la respuesta cerebral relevante para la tarea. Este procedimiento permitió sincronizar las señales en relación con el inicio del evento, lo que garantizó coherencia temporal entre las muestras.

Cada segmento fue definido con una duración fija, que permitió obtener representaciones homogéneas en términos de longitud temporal. Esta procedimiento resultó muy útil para su posterior utilización en los modelos, que requieren entradas con dimensiones consistentes. De igual forma, se evitó la inclusión de intervalos previos al estímulo que no aportaran información discriminativa, solo enfocando el análisis en las regiones temporales donde se manifiestan patrones asociados a la imaginación motriz.

La duración de cada ventana se estableció en un intervalo temporal suficiente para capturar la evolución de los ritmos sensorimotrices asociados a la tarea, considerando que las bandas de frecuencia de interés presentan ciclos de varios cientos de milisegundos. La elección de una ventana de duración fija respondió a la necesidad de disponer de una dimensión temporal constante en todas las muestras, lo que permitió definir un tensor de entrada de dimensiones (canales, tiempo) compartido por los tres modelos implementados. Cada muestra quedó compuesta por la actividad de los veintisiete canales registrados durante la ventana temporal considerada.

La segmentación generó múltiples muestras independientes a partir de cada registro continuo, se incrementó el número de ejemplos disponibles para el entrenamiento. Este incremento en la cantidad de datos permitió mejorar la capacidad de generalización de los modelos, al exponerlos a una mayor variabilidad intra e intersujeto.

Adicionalmente, se mantuvo la correspondencia entre cada segmento y su respectiva etiqueta de clase, lo que preservó la integridad del conjunto de datos supervisado. Este proceso permitió transformar las señales EEG continuas en un conjunto estructurado de muestras etiquetadas, adecuado para su utilización en tareas de clasificación.

3.2.4. Estandarización y control de calidad

Tras la segmentación, se aplicó una etapa de estandarización por muestra con el objetivo de homogeneizar la escala de amplitud de las señales. Las señales EEG presentan una variabilidad natural de amplitud tanto entre sujetos como entre ensayos de un mismo sujeto, dependiendo de factores como el grosor del cuero cabelludo, la impedancia de los electrodos o el nivel de activación cortical. Esta variabilidad podría sesgar el aprendizaje si las muestras se alimentaran al modelo con escalas heterogéneas. Por ello, cada muestra se normalizó de modo que sus valores presentaran una media nula y una desviación estándar unitaria, lo que permitió que las arquitecturas aprendieran a partir de la forma relativa de las señales y no de su magnitud absoluta.

Complementariamente, se llevó a cabo un control de calidad orientado a detectar segmentos anómalos que pudieran degradar el entrenamiento. Si bien el conjunto de datos fue provisto en un formato curado, se verificó la ausencia de valores

faltantes o de amplitudes fuera de rango en los canales registrados. Los segmentos que presentaran indicios de saturación del conversor analógico-digital o de desconexión de un electrodo fueron descartados del conjunto de entrenamiento. Este procedimiento contribuyó a mantener la integridad estadística de los datos y a reducir el riesgo de que el modelo aprendiera patrones asociados a artefactos en lugar de a la actividad cerebral de interés.

El resultado de la cadena de preprocesamiento consistió en un conjunto de muestras tensoriales de dimensiones (canales, tiempo), cada una asociada a una etiqueta binaria de imaginación motriz. Esta representación uniforme fue la que alimentó a las arquitecturas de redes neuronales descritas en la siguiente sección, garantizando compatibilidad dimensional entre los datos y las capas de entrada de los modelos.

En la tabla 3.1, se presentan los parámetros utilizados durante las etapas de preparación y preprocesamiento de las señales EEG.

TABLA 3.1. Parámetros de preparación y preprocesamiento de señales EEG.

Etapa	Parámetro	Valor
Preparación	Dataset	Dreyer2023
	Acceso a datos	MOABB
	Número de sujetos	60
	Tipo de tarea	Imaginación motriz
	Clases	Mano izquierda / Mano derecha
	Número de canales EEG	27
	Sistema de electrodos	10-20
	Frecuencia de muestreo	512 Hz
	Número de runs por sesión	6
	Ensayos por run	40
Preprocesamiento	Tipo de señal	Señales crudas
	Filtro aplicado	Pasa banda
	Rango de filtrado	8–30 Hz
	Bandas analizadas	μ (8–13 Hz), β (13–30 Hz)
Segmentación	Tipo de ventana	Epochs alineados a estímulo
	Intervalo temporal	Posterior al estímulo
Normalización	Duración de ventana	Fija
	Tipo	Estandarización por muestra
Estructuración	Formato de entrada	(canales $\times$ tiempo)

3.3. Desarrollo de modelos

En esta sección se describe el desarrollo de los modelos implementados para la clasificación de señales EEG en tareas de imaginación motriz. Inicialmente, se presenta el modelo basado en redes convolucionales CNN. Posteriormente, se describe el modelo basado en redes neuronales recurrentes RNN, y finalmente, se presenta el modelo híbrido CNN-RNN. Asimismo, se describen las configuraciones establecidas en las diferentes capas que conformaron los modelos.




FIGURA 3.2. Arquitectura general del modelo de clasificación de señales EEG implementado.

3.3.1. Modelo basado en redes convolucionales

La estructura de entrada del modelo se definió para procesar las secuencias temporales provenientes de los veintisiete canales EEG del conjunto de datos Dreyer2023A [10]. Esta representación preservó la estructura espacial de los electrodos y la evolución temporal de las señales, lo que permitió al modelo de capas convolucionales capturar patrones locales presentes en las señales EEG.

Las primeras capas convolucionales se configuraron para extraer patrones temporales de corta duración asociados a variaciones espectrales presentes en las bandas μ y β [2, 12]. Posteriormente, se aplicaron convoluciones espaciales orientadas a modelar relaciones entre diferentes canales EEG. Este enfoque permitió capturar información distribuida sobre distintas regiones en las señales EEG.

El funcionamiento de estas capas consistió en desplazar un núcleo de convolución a lo largo de la dimensión temporal de la señal, de modo que cada posición del núcleo produjo una combinación lineal ponderada de las muestras vecinas. Este mecanismo permitió detectar la presencia de patrones de corta duración, como los ciclos característicos de las bandas de frecuencia mencionadas, independientemente del instante exacto en el que ocurrieran. Por su parte, la convolución espacial operó sobre el eje de los canales, de modo que cada filtro combinó la

actividad de varios electrodos simultáneamente y produjo un mapa de características que representó la co-activación de las regiones corticales involucradas en la imaginación motriz.

Cada bloque convolucional estuvo compuesto por una capa de convolución seguida de una función de activación y una operación de reducción de dimensionalidad. Las funciones de activación introdujeron la no linealidad necesaria para que el modelo representara relaciones complejas entre las muestras de entrada, mientras que las operaciones de reducción agregaron la información contenida en pequeñas regiones temporales, lo que redujo la resolución de las representaciones y la cantidad de parámetros de las capas posteriores. Este diseño escalonado permitió que el modelo extrajera inicialmente patrones locales y, a medida que se profundizaba, combinaciones cada vez más globales de la señal.

Después de las capas convolucionales, se incorporaron funciones de activación no lineales y capas de normalización. Estas capas estabilizaron la distribución interna de las representaciones generadas durante el entrenamiento y favorecieron la convergencia del modelo. Asimismo, se utilizaron operaciones de reducción dimensional, que disminuyeron la complejidad computacional y redujeron la redundancia presente en las características extraídas.

Con el propósito de reducir el sobreajuste, se incorporó la técnica de dropout [13] en diferentes etapas de la arquitectura. Este mecanismo realizó una desactivación aleatoria de neuronas durante el entrenamiento, que evitó una dependencia excesiva de patrones específicos presentes en el conjunto de datos. Su utilización resultó relevante debido a la variabilidad intra e intersujeto característica de las señales EEG.

En las etapas finales del modelo, se utilizaron capas densamente conectadas encargadas de integrar las representaciones espaciales y temporales aprendidas previamente. Estas capas transformaron las características extraídas en probabilidades asociadas a cada clase de imaginación motriz. La salida del modelo se configuró para realizar una clasificación binaria correspondiente a tareas de imaginación motriz de mano izquierda y mano derecha presentes en el conjunto Dreyer2023A.

La arquitectura convolucional implementada permitió procesar señales EEG multicanal y aprender representaciones discriminativas directamente desde los datos preprocesados. Este enfoque evitó la necesidad de definir manualmente características espectrales o espaciales antes del entrenamiento, que favoreció un flujo de procesamiento más uniforme e integrado.

3.3.2. Modelo basado en redes neuronales recurrentes

La estructura de entrada del modelo se definió a partir de secuencias temporales organizadas por los canales de EEG y muestras en el tiempo. Esta representación preservó la evolución temporal de la actividad cerebral presente en cada ensayo. A diferencia de las arquitecturas convolucionales, el modelo recurrente priorizó el análisis de dependencias temporales entre diferentes instantes de la señal EEG.

La arquitectura recurrente se basó en capas LSTM que procesaron secuencialmente la información temporal presente en cada segmento de EEG. Se definió una configuración de dos capas apiladas con sesenta y cuatro unidades ocultas cada una; esta estructura favoreció la mitigación de la pérdida de información a través

de sus mecanismos de compuertas. Dichos elementos internos regularon el flujo de datos para retener las características relevantes provenientes de los estados anteriores. Como resultado, el modelo logró establecer una relación sólida entre las variaciones de amplitud de los veintisiete canales electroencefalográficos y la intención motriz evaluada.

El procesamiento de cada muestra se realizó de forma secuencial a lo largo del eje temporal. En cada paso, la unidad recurrente recibió la muestra correspondiente a un instante determinado, junto con el estado oculto y el estado de memoria provenientes del paso anterior. El mecanismo de compuertas decidió qué información debía descartarse del estado de memoria, qué nueva información debía incorporarse y qué parte del estado debía emitirse hacia el siguiente paso. Este procedimiento permitió que el modelo mantuviera, a lo largo de toda la ventana temporal, el contexto necesario para interpretar la evolución de la actividad cerebral. El apilamiento de dos capas LSTM permitió además que la segunda capa operara sobre las representaciones temporales ya depuradas por la primera, lo que favoreció el aprendizaje de dependencias de más largo alcance dentro de cada ensayo.

De igual manera que en el modelo basado en redes convolucionales, se incorporaron funciones de activación no lineales, mecanismos de regularización y capas orientadas a estabilizar el proceso de entrenamiento. Estas configuraciones favorecieron la convergencia del modelo y contribuyeron a mejorar la estabilidad de las representaciones internas generadas durante el aprendizaje.

En las etapas finales del modelo, se utilizaron capas densamente conectadas encargadas de integrar las representaciones temporales aprendidas previamente por las capas LSTM. Estas capas transformaron las características extraídas en probabilidades asociadas a cada clase de imaginación motriz. La salida del modelo se configuró para realizar una clasificación binaria correspondiente a tareas de imaginación motriz de mano izquierda y mano derecha presentes en el conjunto Dreyer2023A.

La arquitectura basada en capas LSTM permitió procesar secuencias temporales de señales EEG multicanal y modelar dependencias temporales presentes en las tareas de imaginación motriz. Este enfoque permitió aprender representaciones asociadas a la dinámica temporal de la actividad cerebral directamente a partir de los datos preprocesados, lo que evitó la definición manual de características temporales antes del entrenamiento.

3.3.3. Modelo híbrido basado en CNN-LSTM

El tercer modelo implementado correspondió a una arquitectura híbrida basada en redes convolucionales y redes neuronales recurrentes LSTM. Este enfoque integró las capacidades de extracción espacial de las arquitecturas convolucionales con el modelado temporal proporcionado por las capas LSTM. Esta combinación de arquitecturas permitió procesar simultáneamente características espaciales y temporales en las señales EEG asociadas a tareas de imaginación motriz.

La estructura de entrada se definió a partir de segmentos EEG organizados en matrices bidimensionales compuestas por canales y muestras temporales. La primera etapa de la arquitectura correspondió a un bloque de redes convolucionales

configurado para procesar los canales EEG presentes en el conjunto de datos Dreyer2023A. Estas capas realizaron la extracción de características espaciales locales presentes en las señales EEG e identificaron patrones asociados a variaciones entre diferentes canales y regiones relacionadas con tareas de imaginación motriz.

Posteriormente, las representaciones generadas por las capas convolucionales fueron procesadas mediante capas LSTM. Estas capas analizaron la evolución temporal de las características extraídas previamente, lo que permitió modelar dependencias temporales presentes a lo largo de la señal EEG. La integración entre capas convolucionales y recurrentes permitió capturar simultáneamente información espacial y temporal durante el proceso de aprendizaje.

La transición entre ambos bloques requirió reorganizar las representaciones convolucionales en una secuencia temporal apta para el procesamiento recurrente. Cada mapa de características producido por el bloque convolucional se reordenó de modo que la dimensión temporal quedara alineada con la secuencia de entrada de las capas LSTM, mientras que las características espaciales de cada instante se agruparon como los atributos de ese paso temporal. De esta manera, la capa recurrente recibió, para cada instante de la ventana, el conjunto de características espaciales extraídas por la convolución, y modeló cómo estas características evolucionaban entre instantes consecutivos. Esta disposición evitó que el modelo dependiera de una representación temporal promediada y permitió explotar la dinámica fina de la señal.

De igual manera que en las arquitecturas previamente descritas, se incorporaron funciones de activación no lineales, mecanismos de regularización y capas de dropout orientadas a mejorar la estabilidad del entrenamiento y disminuir así el sobreajuste. Estas configuraciones favorecieron la capacidad de generalización del modelo frente a señales EEG provenientes de distintos sujetos y ensayos.

En las etapas finales del modelo, se utilizaron capas densamente conectadas encargadas de integrar las representaciones espaciales y temporales aprendidas por la arquitectura híbrida. Estas capas transformaron las características extraídas en probabilidades asociadas a cada clase de imaginación motriz. La salida del modelo se configuró para realizar una clasificación binaria correspondiente a tareas de imaginación motriz de mano izquierda y mano derecha presentes en el conjunto Dreyer2023A.

La arquitectura híbrida implementada permitió combinar la capacidad de extracción espacial de las redes convolucionales con el modelado temporal de las capas LSTM. Este enfoque favoreció el aprendizaje conjunto de patrones espaciales y dinámicas temporales presentes en las señales EEG asociadas a tareas de imaginación motriz.

Para facilitar la comparación entre las tres arquitecturas implementadas, se definió una representación común de sus principales características estructurales. Esta representación contempló la forma en que cada modelo recibe los datos de entrada, las capas responsables de la extracción de rasgos, los mecanismos de regularización empleados y la manera en que se produce la decisión final de clasificación.

En primer lugar, las arquitecturas CNN y CNN-LSTM operaron sobre segmentos EEG multicanal organizados en matrices de canales por tiempo, mientras que la arquitectura RNN-LSTM procesó secuencias temporales de las señales. Esta

distinción condicionó el tratamiento espacial de los datos: las dos primeras arquitecturas contaron con capas convolucionales capaces de explotar la correlación entre canales adyacentes, mientras que el modelo recurrente basó su análisis únicamente en la evolución temporal de la señal. No obstante, las tres arquitecturas compartieron el uso de capas LSTM para el modelado de las dependencias temporales, con sesenta y cuatro unidades ocultas en los casos en que esta capa estuvo presente.

En cuanto a la regularización, los tres modelos incorporaron dropout en distintas etapas de su estructura, junto con capas de normalización orientadas a estabilizar el proceso de entrenamiento. La inclusión de estos mecanismos resultó especialmente relevante para mitigar el sobreajuste, dado que las señales EEG presentan una alta variabilidad entre sujetos y ensayos. Finalmente, todas las arquitecturas concluyeron con capas densamente conectadas que transformaron las representaciones aprendidas en una salida de clasificación binaria, correspondiente a las tareas de imaginación motriz de mano izquierda y mano derecha del conjunto Dreyer2023A.

A continuación, se presentan las configuraciones principales utilizadas en las arquitecturas implementadas para la clasificación de señales EEG en tareas de imaginación motriz.

TABLA 3.2. Configuración de las arquitecturas implementadas.

Componente	CNN	RNN-LSTM	CNN-LSTM
Entrada	Segmentos EEG multicanal	Secuencias temporales EEG	Segmentos EEG multicanal
Representación de entrada	(canales $\times$ tiempo)	(canales $\times$ tiempo)	(canales $\times$ tiempo)
Capas principales	Capas convolucionales	Capas LSTM	Capas convolucionales y LSTM
Extracción espacial	Sí	No	Sí
Modelado temporal	Limitado	Sí	Sí
Capas recurrentes	No aplica	2	1
Unidades ocultas	No aplica	64	64
Regularización	Dropout	Dropout	Dropout
Normalización	Sí	Sí	Sí
Capas densas finales	Sí	Sí	Sí
Salida	Clasificación binaria	Clasificación binaria	Clasificación binaria
Clases	Mano izquierda / derecha	Mano izquierda / derecha	Mano izquierda / derecha
Dataset	Dreyer2023A	Dreyer2023A	Dreyer2023A

3.4. Configuración del entrenamiento

En esta sección se describen las configuraciones utilizadas durante el proceso de entrenamiento de los modelos, así como la estrategia de búsqueda de hiperparámetros aplicada para optimizar el desempeño en la clasificación de señales EEG asociadas a tareas de imaginación motriz.

El proceso de entrenamiento se realizó utilizando los segmentos EEG obtenidos durante las etapas de preparación y preprocesamiento descritas previamente. Las muestras fueron organizadas en conjuntos de entrenamiento y validación, lo que permitió evaluar el comportamiento de las arquitecturas implementadas durante el aprendizaje.

La partición de los datos se realizó considerando la organización del conjunto Dreyer2023A por sujetos. Se reservó una porción de los sujetos para el conjunto de validación, de modo que el modelo nunca observara durante el entrenamiento las señales de los sujetos empleados para su evaluación. Esta estrategia de partición por sujetos, en lugar de por ensayos, resultó determinante para medir la capacidad de generalización del sistema frente a usuarios no vistos, que constituye el escenario de interés en una interfaz cerebro-computador real. La proporción entre sujetos de entrenamiento y de validación se mantuvo constante en todas las arquitecturas evaluadas, lo que garantizó la comparabilidad de los resultados obtenidos.

3.4.1. Ciclo de entrenamiento

El entrenamiento de cada arquitectura se organizó en un ciclo iterativo compuesto por dos fases: una fase de avance y una fase de retropropagación. En la fase de avance, las muestras de un lote se propagaron a través de las capas del modelo hasta producir una predicción para cada una. A continuación, se calculó la función de pérdida comparando las predicciones generadas con las etiquetas reales correspondientes a cada muestra. La función de pérdida utilizada correspondió a la entropía cruzada binaria, cuya formulación penaliza de manera creciente las predicciones que se alejan de la clase real, lo que orienta el aprendizaje hacia una decisión de clasificación correcta.

En la fase de retropropagación, el gradiente de la función de pérdida con respecto a cada parámetro del modelo se calculó mediante la regla de la cadena, recorriendo las capas en orden inverso. El optimizador Adam [14] utilizó estos gradientes para actualizar los pesos del modelo, ajustando la magnitud del cambio según la tasa de aprendizaje configurada y manteniendo estimaciones de los momentos de primer y segundo orden que aceleraron la convergencia. Este procedimiento se repitió para todos los lotes que componían el conjunto de entrenamiento, completando una época de entrenamiento.

Al finalizar cada época, se evaluó el desempeño del modelo sobre el conjunto de validación. Se incorporó un mecanismo de detención temprana, mediante el cual el entrenamiento se interrumpió cuando el desempeño en validación dejó de mejorar durante un número consecutivo de épocas. Esta estrategia evitó el sobreajuste y redujo el tiempo computacional dedicado a épocas sin progreso. Además, se conservó como modelo final aquel que presentó el mejor desempeño en el conjunto de validación, en lugar de aquel correspondiente a la última época del entrenamiento.

Con el propósito de optimizar el desempeño de los modelos, se realizó una búsqueda de hiperparámetros orientada a identificar configuraciones adecuadas para cada arquitectura. Este procedimiento consideró parámetros relacionados con la capacidad de aprendizaje, estabilidad del entrenamiento y capacidad de generalización frente a señales EEG provenientes de distintos sujetos y ensayos.

En esta fase del desarrollo se implementó un proceso de búsqueda automatizada para definir la configuración estructural y de entrenamiento de los modelos propuestos. Debido a que la selección manual de hiperparámetros resulta intensiva a nivel computacional y susceptible al sesgo humano, se utilizó el entorno de optimización Optuna [15]; esta herramienta permitió explorar el espacio de soluciones de manera eficiente y sistemática.

El proceso de optimización requirió la definición de un espacio de búsqueda específico para cada una de las tres arquitecturas evaluadas. Las variables transversales a todos los modelos incluyeron la tasa de aprendizaje del optimizador, el tamaño del lote de datos y el dropout. Para el modelo CNN, el espacio de exploración abarcó adicionalmente la cantidad de filtros por bloque y las dimensiones de los núcleos convolucionales. En el caso de la arquitectura RNN, la herramienta iteró sobre el número óptimo de unidades ocultas dentro de las capas LSTM. Finalmente, para el enfoque híbrido, se asignó un rango de búsqueda que combinó los parámetros de extracción espacial y de modelado temporal; esto garantizó una sintonización conjunta y equilibrada de ambas etapas de procesamiento.

La automatización se estructuró en torno a una función objetivo, esta se encargó de guiar el proceso de búsqueda y para cada combinación de parámetros sugerida de dicha función instanció la red neuronal correspondiente, se ejecutó un ciclo de entrenamiento completo y evaluó el desempeño del sistema. En lugar de utilizar la exactitud global como único indicador, se seleccionó la métrica F1-score para cuantificar el rendimiento; este indicador calculó el balance entre la precisión y la exhaustividad de manera independiente para cada clase. Su uso resultó fundamental para obtener una evaluación rigurosa del comportamiento del modelo frente a las señales de EEG, pues penalizó de forma severa tanto los falsos positivos como los falsos negativos sin que una clase predominara sobre la otra.

La estrategia de búsqueda empleada por el entorno se basó en la estimación bayesiana del espacio de hiperparámetros. A diferencia de una búsqueda en cuadrícula exhaustiva, este enfoque modeló la relación entre las configuraciones evaluadas y el desempeño obtenido, de modo que las iteraciones sucesivas se concentraron en las regiones del espacio donde era más probable encontrar configuraciones superiores. Esta metodología permitió explorar espacios de búsqueda de alta dimensionalidad con un número acotado de ensayos, lo que resultó especialmente ventajoso dado el costo computacional de cada ciclo de entrenamiento completo.

Durante el desarrollo de la experimentación se monitoreó la evolución de las funciones de pérdida sobre los conjuntos de entrenamiento y validación para cada configuración evaluada. El seguimiento de estas curvas permitió verificar la convergencia del entrenamiento, detectar posibles episodios de sobreajuste y confirmar que los criterios de detención temprana operaran de manera adecuada. La inspección de las curvas de pérdida constituyó un control de calidad complementario a las métricas de desempeño, dado que evidenció si el modelo estaba aprendiendo los patrones de la señal o si el proceso de optimización presentaba inestabilidades.

A continuación, se presentan los principales hiperparámetros considerados durante el entrenamiento de las arquitecturas implementadas.

TABLA 3.3. Hiperparámetros utilizados durante el entrenamiento.

Hiperparámetro	Configuración evaluada
Número de capas convolucionales	1 a 3 capas
Número de filtros	16 a 128 filtros
Tamaño de kernel	3 y 5
Unidades ocultas LSTM	64 unidades
Dropout	0,1 a 0,5
Tamaño de capa densa	64 a 256 neuronas
Tasa de aprendizaje	Ajuste experimental
Batch size	Ajuste experimental
Número de épocas	Definido experimentalmente
Optimizador	Adam
Función de pérdida	Clasificación binaria
Métricas monitoreadas	Accuracy, Precision, Recall y F1-score

3.5. Protocolo de evaluación

En esta sección se describen las métricas y el procedimiento utilizado para evaluar el desempeño de las arquitecturas implementadas en la clasificación de señales EEG asociadas a tareas de imaginación motriz.

La evaluación de los modelos se realizó utilizando los conjuntos de validación definidos durante el proceso de entrenamiento. Este procedimiento permitió analizar el comportamiento de las arquitecturas CNN, LSTM y CNN-LSTM frente a señales EEG no observadas previamente, lo que facilitó la comparación de su capacidad de generalización sobre tareas de imaginación motriz.

Debido a la naturaleza de clasificación binaria del conjunto Dreyer2023A, la evaluación se orientó a medir la capacidad de los modelos para discriminar correctamente entre tareas de imaginación motriz de mano izquierda y mano derecha. Para ello, se emplearon métricas ampliamente utilizadas en problemas de clasificación aplicados a aprendizaje profundo y análisis de señales EEG [6, 12].

El protocolo de evaluación se aplicó de manera idéntica sobre las tres arquitecturas implementadas, con el objetivo de garantizar condiciones comparables entre los modelos. Cada muestra del conjunto de validación se presentó al modelo, que generó para cada una un puntaje de pertenencia a las clases de imaginación motriz. El puntaje obtenido se comparó con un umbral de decisión, a partir del cual se asignó la etiqueta predicha. Este procedimiento permitió cuantificar, para cada arquitectura, el número de aciertos y errores desagregado por clase, sobre el cual se calcularon posteriormente las métricas de desempeño.

Debido a que las dos tareas de imaginación motriz presentaron una distribución balanceada de muestras en el conjunto de datos, la exactitud constituyó un indicador inicial razonable del desempeño global. No obstante, se prestó especial atención a las métricas derivadas de la matriz de confusión, dado que estas desagregaron el comportamiento del modelo para cada clase de manera independiente.

Esta desagregación resultó relevante para detectar posibles sesgos del modelo hacia una de las dos tareas, situación que la exactitud global podría enmascarar.

La principal métrica utilizada correspondió a la exactitud (accuracy), la que permitió medir la proporción de predicciones correctas realizadas por el modelo sobre el total de muestras evaluadas. Esta métrica proporcionó una medida general del desempeño alcanzado por las arquitecturas implementadas. Adicionalmente, se utilizaron métricas de precisión (precision), exhaustividad (recall) y puntuación F1 (F1-score). Estas métricas permitieron evaluar el comportamiento del modelo desde diferentes perspectivas relacionadas con la calidad de las predicciones realizadas.

La precisión permitió medir la proporción de tareas de imaginación motriz clasificadas correctamente respecto al total de predicciones positivas generadas por el modelo. Esta métrica resultó relevante para analizar la confiabilidad de las clasificaciones obtenidas a partir de patrones presentes en las señales EEG, especialmente en escenarios donde variaciones corticales similares pueden generar ambigüedad entre clases.

La exhaustividad permitió medir la capacidad del modelo para identificar correctamente muestras EEG pertenecientes a cada tarea de imaginación motriz. Esta métrica resultó importante para evaluar la sensibilidad de las arquitecturas frente a patrones temporales y espaciales asociados a la actividad cortical registrada durante la imaginación motriz de mano izquierda y mano derecha.

Por otra parte, la puntuación F1 permitió integrar precisión y exhaustividad en una única métrica de desempeño. Esta medida facilitó la evaluación equilibrada del comportamiento de los modelos frente a la variabilidad inherente de las señales EEG, lo que proporcionó una medida más robusta del desempeño general de las arquitecturas implementadas [6, 12].

Durante la evaluación, se monitoreó el comportamiento de las métricas sobre los conjuntos de entrenamiento y validación, lo que permitió identificar posibles casos de sobreajuste y analizar la estabilidad de las arquitecturas implementadas. Asimismo, se evaluó la capacidad de generalización de los modelos frente a señales EEG provenientes de distintos sujetos y ensayos, aspecto relevante debido a la alta variabilidad intra e intersujeto presente en tareas de imaginación motriz.

Para incrementar la confiabilidad de las conclusiones, cada arquitectura se evaluó mediante la repetición del proceso de entrenamiento y evaluación en ejecuciones independientes. Las métricas obtenidas en cada ejecución se promediaron y se reportó además su desviación, lo que permitió cuantificar la estabilidad del desempeño ante la variabilidad aleatoria inherente a la inicialización de los pesos y a la selección de los lotes de entrenamiento. Este procedimiento contribuyó a distinguir diferencias de desempeño genuinas entre las arquitecturas de diferencias que pudieran atribuirse al azar, y constituyó la base sobre la que se compararon los modelos en el capítulo de ensayos y resultados.

A continuación, en la tabla 3.4 se presentan las métricas utilizadas para la evaluación de los modelos implementados en la clasificación de señales EEG asociadas a tareas de imaginación motriz.

TABLA 3.4. Métricas utilizadas para la evaluación de modelos EEG en tareas de imaginación motriz.

Métrica	Descripción estadística	Relevancia en señales EEG
Exactitud	Proporción de predicciones correctas sobre el total de muestras EEG evaluadas.	Ofreció una visión global del desempeño alcanzado por las arquitecturas neuronales durante la clasificación de tareas de imaginación motriz.
Precisión	Relación entre verdaderos positivos y el total de predicciones positivas realizadas por el modelo.	Indicó la confiabilidad del modelo al identificar patrones EEG asociados a tareas de imaginación motriz de mano izquierda y mano derecha.
Exhaustividad	Relación entre verdaderos positivos y el total de muestras reales pertenecientes a una clase.	Permitió evaluar la capacidad del modelo para identificar correctamente señales EEG asociadas a la intención motriz del usuario.
Puntuación F1	Media armónica entre precisión y exhaustividad calculada sobre las clases evaluadas.	Constituyó una métrica robusta para comparar el desempeño de las arquitecturas CNN, LSTM y CNN-LSTM frente a la variabilidad presente en señales EEG.

3.6. Despliegue del modelo

En esta sección se describe el procedimiento de despliegue implementado para el modelo seleccionado, así como la infraestructura utilizada para realizar la inferencia sobre señales electroencefalográficas (EEG) asociadas a tareas de imaginación motriz. El objetivo de esta etapa fue trasladar el modelo obtenido durante el proceso experimental a un entorno de ejecución independiente, capaz de recibir señales EEG, realizar el procesamiento requerido y generar las predicciones correspondientes de manera reproducible.

El despliegue se realizó mediante una arquitectura cloud basada en servicios de Amazon Web Services (AWS), orientada a desacoplar las diferentes etapas que intervienen en el ciclo de ejecución del sistema. En particular, se estableció una separación entre el entorno utilizado para el entrenamiento y evaluación del modelo y el entorno destinado a la inferencia. Esta separación permite que los recursos computacionales empleados durante el entrenamiento no sean necesarios durante la ejecución del modelo, lo que reduce las dependencias entre ambos entornos y facilitando la integración con otros componentes del sistema.

El proceso de despliegue inició con la serialización sistemática de los modelos obtenidos durante la etapa de entrenamiento. Esta operación permitió conservar una representación persistente del modelo seleccionado una vez alcanzado su mejor desempeño durante la validación. Para ello, se almacenó el estado de los parámetros aprendidos de la arquitectura mediante los correspondientes diccionarios de estado, preservando los valores de los parámetros necesarios para reconstruir posteriormente el modelo. Este procedimiento permitió separar la definición de la arquitectura del estado aprendido durante el entrenamiento y facilitó la posterior transferencia del modelo hacia el entorno destinado a inferencia.

De forma complementaria, la gestión del ciclo de vida de los experimentos de aprendizaje automático se realizó mediante MLflow [16]. Esta plataforma permitió organizar las diferentes ejecuciones como experimentos independientes y mantener un registro estructurado de los resultados obtenidos durante el proceso de entrenamiento. En particular, se registraron los hiperparámetros utilizados, las métricas de desempeño, los artefactos generados y los metadatos asociados a cada ejecución. Esta trazabilidad permitió identificar de manera reproducible la configuración correspondiente al modelo finalmente seleccionado y establecer una relación entre los resultados experimentales y el artefacto utilizado posteriormente durante el despliegue.

Posteriormente, el modelo fue exportado utilizando el formato ONNX (*Open Neural Network Exchange*), lo que permitió convertir la arquitectura entrenada a un formato portable e interoperable. Este enfoque facilitó la ejecución del modelo fuera del entorno original de entrenamiento y permitió su integración con diferentes plataformas de inferencia, servicios cloud y entornos de producción. La utilización de ONNX favoreció la portabilidad del sistema y redujo dependencias específicas del framework utilizado durante el entrenamiento.

El proceso de exportación consistió en traducir la representación computacional del modelo, definida inicialmente dentro del framework de entrenamiento, a un grafo estandarizado de operaciones descrito en el formato ONNX. Cada capa de la arquitectura, junto con sus parámetros aprendidos y su configuración de activación, se codificó como un nodo del grafo de computación. Esta representación unificada permitió que el modelo fuera ejecutado por un motor de inferencia independiente, que interpreta el grafo y realiza las operaciones de manera optimizada. Como parte de la conversión, se verificó que las predicciones producidas por el modelo exportado fueran consistentes con las producidas por el modelo original dentro del framework de entrenamiento, comparando las salidas obtenidas sobre un conjunto de muestras de referencia. Esta validación de equivalencia resultó esencial para garantizar que la conversión no introdujera discrepancias en el comportamiento del sistema.

El artefacto resultante se almacenó en un servicio de almacenamiento en la nube, desde donde fue recuperado posteriormente por el entorno de inferencia. La separación entre el almacenamiento del artefacto y el entorno de ejecución permitió actualizar el modelo desplegado sin modificar el código de la infraestructura, dado que bastó con reemplazar el artefacto almacenado y reiniciar el servicio.

El entorno de inferencia fue desplegado sobre servicios serverless de AWS, utilizando funciones Lambda para ejecutar el procesamiento del modelo de manera remota. Asimismo, se desarrolló una API REST utilizando FastAPI, encargada de gestionar las solicitudes de inferencia y la comunicación entre el cliente y el modelo desplegado. Este enfoque permitió escalar dinámicamente el sistema frente a múltiples solicitudes de inferencia y reducir el consumo de recursos cuando no existían peticiones activas.

3.6.1. Infraestructura de inferencia

El servicio de inferencia se compuso de dos capas complementarias. La primera capa correspondió a la API REST, cuya responsabilidad consistió en recibir las solicitudes de predicción provenientes de los clientes, validar el formato de

los datos recibidos y coordinar el flujo de procesamiento. La segunda capa correspondió a las funciones Lambda, que ejecutaron la carga del modelo ONNX y la computación de la inferencia sobre las muestras preprocesadas. La separación entre ambas capas permitió que la API actuara como punto de entrada único y estable del sistema, mientras que el cómputo intensivo quedó delegado a las funciones ejecutadas bajo demanda.

El flujo interno de cada solicitud se estructuró en varias etapas. Inicialmente, la API REST recibió los datos crudos de las señales EEG y aplicó sobre ellos el mismo preprocesamiento definido durante el entrenamiento, compuesto por el filtrado pasa banda, la segmentación y la estandarización por muestra. Esta réplica del preprocesamiento en el entorno de inferencia resultó fundamental para garantizar que las muestras evaluadas por el modelo desplegado presentaran la misma distribución que las muestras utilizadas durante la validación. Posteriormente, la representación preprocesada se transmitió a la función Lambda, que cargó el modelo ONNX desde el almacenamiento y calculó la predicción correspondiente. Por último, la API REST tradujo el resultado a una respuesta estructurada y la devolvió al cliente que había originado la solicitud.

Dado que el modelo y sus dependencias debían estar disponibles en el entorno de ejecución de las funciones, el artefacto ONNX y las bibliotecas necesarias para su interpretación se empaquetaron conjuntamente. La configuración de la función asignó una cantidad de memoria acorde con el tamaño del modelo, de modo que el artefacto pudiera cargarse en memoria al inicio de cada invocación. La naturaleza serverless del servicio permitió que las funciones se ejecutaran únicamente ante la llegada de una solicitud, sin incurrir en costos de cómputo durante los períodos de inactividad. Además, ante un incremento en la cantidad de solicitudes concurrentes, el servicio escaló automáticamente la cantidad de instancias de ejecución, sin requerir intervención manual sobre la infraestructura.

El monitoreo del servicio se realizó mediante el servicio de observabilidad de la plataforma cloud, que registró los eventos de cada invocación, los tiempos de respuesta y los posibles errores ocurridos durante el procesamiento. Estos registros permitieron diagnosticar fallas, dimensionar el consumo de recursos y verificar el correcto funcionamiento del sistema en condiciones de carga variable. La información de monitoreo constituyó, además, la base para estimar los costos asociados al despliegue, que se detallan a continuación.

A continuación, en la tabla 3.5 se presentan los principales componentes considerados durante el despliegue y una estimación mensual asociada al coste de inferencia de señales EEG para un prototipo inicial.

TABLA 3.5. Estimación de costos de despliegue e inferencia del sistema EEG.

Componente	Descripción	Consumo	Costo unitario (USD)	Costo mensual (USD)
API Gateway	Gestión de solicitudes REST.	10 000 solicitudes	3,50 por 1 000 000 solicitudes	0,04
AWS Lambda	Inferencia del modelo EEG.	100 000 GB-segundos	0,0000166 por GB-segundo	1,67
Amazon S3	Almacenamiento del modelo ONNX.	1 GB estándar	0,023 por GB mensual	0,02
CloudWatch	Monitoreo y registros del sistema.	1 GB procesado	0,50 por GB procesado	0,50
Transferencia de datos	Tráfico de salida.	1 GB de salida	0,09 por GB	0,09
Costo total	Operación mensual estimada.	-	-	2,32

El flujo de inferencia inició con la recepción de señales EEG desde un cliente, que pudieron provenir de un dispositivo de adquisición o de un sistema de almacenamiento. Estas señales fueron enviadas a la API REST desplegada en AWS, que se encargó de recibir las solicitudes y gestionar la comunicación con el modelo de inferencia.

De forma complementaria, la API REST realizó un preprocesamiento de las señales EEG recibidas, replicando los mismos pasos utilizados durante el entrenamiento del modelo. Este procedimiento aseguró que las señales fueran consistentes con el formato y las características esperadas por la arquitectura entrenada. Posteriormente, las señales preprocesadas fueron enviadas al modelo desplegado en AWS, que realizó la inferencia y generó las predicciones correspondientes a cada tarea de imaginación motriz. Finalmente, las predicciones fueron devueltas al cliente a través de la API REST, completando así el ciclo de inferencia del sistema.

A continuación, se describe el flujo general de despliegue e inferencia implementado para el procesamiento de señales EEG asociadas a tareas de imaginación motriz.²

²El diagrama de flujo del despliegue y la inferencia se ilustra en la figura 3.3.




FIGURA 3.3. Flujo de despliegue e inferencia del modelo de clasificación de señales EEG.

Capítulo 4

Ensayos y resultados

En este capítulo se presentan los ensayos realizados para evaluar el desempeño del sistema de clasificación de tareas de imaginación motriz. Se describe el protocolo experimental aplicado, el desempeño alcanzado por las arquitecturas implementadas, la capacidad predictiva del sistema y la comparación con enfoques tradicionales, junto con el análisis de los resultados obtenidos.

4.1. Ensayos de modelos

Para el desarrollo de los ensayos se estableció un protocolo experimental orientado a evaluar el comportamiento de las tres arquitecturas implementadas sobre el conjunto Dreyer2023A. El protocolo definió de manera explícita la partición de los datos, la estrategia de evaluación, la configuración de los experimentos y el número de ejecuciones, con el fin de garantizar condiciones comparables entre los modelos y la reproducibilidad de los resultados.

La partición del conjunto de datos se realizó considerando la organización del conjunto por sujetos. Se asignaron cuarenta y dos sujetos al conjunto de entrenamiento y los dieciocho restantes al conjunto de validación, lo que correspondió a una proporción de setenta por ciento y treinta por ciento, respectivamente. Esta división garantizó que los modelos no observaran durante el entrenamiento las señales de los sujetos empleados para su evaluación, de modo que las métricas obtenidas reflejaron la capacidad de generalización frente a usuarios no vistos. La asignación de sujetos a cada conjunto se mantuvo fija en todas las ejecuciones, lo que permitió comparar el desempeño de las arquitecturas sobre los mismos datos de validación.

La estrategia de evaluación consistió en entrenar cada arquitectura sobre el conjunto de entrenamiento y cuantificar su desempeño sobre el conjunto de validación. Para cada muestra, el modelo generó un puntaje de pertenencia a las clases de imaginación motriz que se comparó con un umbral de decisión. A partir de los aciertos y errores desagregados por clase, se calcularon las métricas de exactitud, precisión, exhaustividad y puntuación F1, cuya definición se presentó en el protocolo de evaluación del capítulo anterior.

La configuración estructural de cada arquitectura se obtuvo mediante el proceso de búsqueda de hiperparámetros descrito en el capítulo anterior. El entorno de optimización ejecutó cincuenta ensayos por arquitectura, explorando los rangos definidos para la tasa de aprendizaje, el tamaño del lote, el dropout y los parámetros estructurales específicos de cada modelo. La configuración que reportó el

mayor desempeño en el conjunto de validación durante la búsqueda fue la adoptada para los ensayos definitivos.

Con el fin de cuantificar la estabilidad del desempeño, cada arquitectura se entrenó y evaluó en diez ejecuciones independientes. Las ejecuciones difirieron únicamente en la inicialización aleatoria de los pesos y en la selección de los lotes de entrenamiento, manteniéndose idénticas la partición de los datos y la configuración de hiperparámetros. Para cada métrica se calculó el promedio y la desviación sobre las diez ejecuciones, de modo que los resultados presentados en las secciones siguientes reflejaron tanto el valor esperado del desempeño como su variabilidad.

En la tabla 4.1 se resume la configuración de los experimentos realizados.

TABLA 4.1. Configuración de los experimentos realizados.

Aspecto	Configuración
Conjunto de datos	Dreyer2023A
Sujetos de entrenamiento	42 (70 %)
Sujetos de validación	18 (30 %)
Arquitecturas evaluadas	CNN, RNN-LSTM y CNN-LSTM
Ensayos de optimización	50 por arquitectura
Ejecuciones independientes	10 por arquitectura
Métricas de desempeño	Exactitud, precisión, exhaustividad y F1

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Jonathan R. Wolpaw et al. «Brain-computer interfaces for communication and control». En: *Clinical Neurophysiology* 113.6 (2002), págs. 767-791.
- [2] Gert Pfurtscheller y Christa Neuper. «Motor imagery and direct brain-computer communication». En: *Proceedings of the IEEE* 89.7 (2001), págs. 1123-1134.
- [3] Alexander J. Casson et al. «Wearable electroencephalography». En: *IEEE Engineering in Medicine and Biology Magazine* 29.3 (2010), págs. 44-56.
- [4] Robin Tibor Schirrmeister et al. «Deep learning with convolutional neural networks for EEG decoding and visualization». En: *Human Brain Mapping* 38.11 (2017), págs. 5391-5420.
- [5] Vernon J. Lawhern et al. «EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 15.5 (2018).
- [6] Yannick Roy et al. «Deep learning-based electroencephalography analysis: a systematic review». En: *Journal of Neural Engineering* 16.5 (2019).
- [7] Pouya Bashivan et al. «Learning representations from EEG with deep recurrent-convolutional neural networks». En: *arXiv preprint arXiv:1511.06448* (2015).
- [8] Alexander Craik, Yongtian He y Jose L. Contreras-Vidal. «Deep learning for electroencephalogram (EEG) classification tasks: a review». En: *Journal of Neural Engineering* 16.3 (2019).
- [9] Fabien Lotte et al. «A review of classification algorithms for EEG-based brain-computer interfaces». En: *Journal of Neural Engineering* 4.2 (2007).
- [10] Alaric M. Dreyer et al. «A large electroencephalography dataset for the study of motor imagery». En: *Scientific Data* 10.1 (2023), pág. 583. DOI: [10.1038/s41597-023-02445-z](https://doi.org/10.1038/s41597-023-02445-z).
- [11] Jaime Riascos, Marta Molinas y Fabien Lotte. «Machine Learning Methods for BCI: challenges, pitfalls and promises». En: *ESANN 2024-European symposium on artificial neural networks, computational intelligence and machine learning*. 2024.
- [12] Ding Zhang et al. «EEG-based brain-computer interfaces using deep learning: A review». En: *Biomedical Signal Processing and Control* 63 (2021), pág. 102172.
- [13] Nitish Srivastava et al. «Dropout: A Simple Way to Prevent Neural Networks from Overfitting». En: *Journal of Machine Learning Research* 15.56 (2014), págs. 1929-1958.
- [14] Diederik P. Kingma y Jimmy Ba. «Adam: A method for stochastic optimization». En: *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*. 2015.
- [15] Takuya Akiba et al. «Optuna: A Next-generation Hyperparameter Optimization Framework». En: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. ACM, 2019, págs. 2623-2631. DOI: [10.1145/3292500.3330701](https://doi.org/10.1145/3292500.3330701).
- [16] Matei Zaharia et al. «Accelerating the Machine Learning Lifecycle with ML-flow». En: *IEEE Data Engineering Bulletin* 41.4 (2018), págs. 39-45.